Empati Sintetis: Psikologi Bahasa AI, Jerat Manipulasi Kognitif, dan Kedaulatan Hukum Individu

Kajian Lintas Disiplin Linguistik Komputasional, Bias Psikologis, dan Kedaulatan Mental

---

Ilham Pradani

ORCID: 0009-0008-1310-6169

PT CHAIN ASIA CONECT Research & Development Division

PT CHAIN ASIA CONECT Publishing Division
Krui, Pesisir Barat & Jakarta, Indonesia

Empati Sintetis: Psikologi Bahasa AI, Jerat Manipulasi Kognitif, dan Kedaulatan Hukum Individu
Kajian Lintas Disiplin Linguistik Komputasional, Bias Psikologis, dan Kedaulatan Mental
Penulis: Ilham Pradani (ORCID: 0009-0008-1310-6169)
Afiliasi: PT CHAIN ASIA CONECT Research & Development Division

Hak Cipta Dilindungi Undang-Undang (All Rights Reserved).
Diterbitkan oleh PT CHAIN ASIA CONECT Research & Monograph Series.
Preprint & Scholarly Registry: CERN Zenodo Open Science Repository.

Cetakan Pertama, 2026
Format Buku: Standar ISO-B5 Percetakan Offset & Print-on-Demand (POD).
Dilarang memperbanyak sebagian atau seluruh isi buku ini tanpa izin tertulis dari penerbit.

Prakata Penulis

Dalam era digital yang semakin didominasi oleh model bahasa berskala besar (LLM), fenomena empati sintetis muncul sebagai kekuatan ganda: sekaligus membuka peluang interaksi manusia-AI yang lebih alami, namun juga menimbulkan risiko manipulasi kognitif yang belum pernah terjadi sebelumnya. Buku ini hadir sebagai respons terhadap kekhawatiran yang meluas di kalangan akademisi, pembuat kebijakan, dan praktisi teknologi mengenai bagaimana persona AI, framing afektif, dan teknik nudging dapat memengaruhi keputusan, persepsi, dan bahkan identitas mental individu.

Latar belakang riset ini berakar pada tiga pilar utama: (1) linguistik komputasional yang mengungkap struktur persuasif dalam output LLM; (2) psikologi kognitif yang menelusuri mekanisme antropomorfisme, bias emosional, serta ikatan parasosial antara pengguna dan agen AI; dan (3) hukum serta hak asasi manusia yang berupaya menegakkan batas pertanggungjawaban atas manipulasi consent, penipuan, serta pelanggaran kedaulatan mental. Dengan mengintegrasikan temuan empiris, analisis normatif, dan rekomendasi kebijakan, monograf ini berupaya menyediakan landasan konseptual dan praktis bagi para peneliti, regulator, dan pembuat keputusan.

Pendekatan interdisipliner yang diusung menekankan pentingnya audit forensik linguistik percakapan AI sebagai metode verifikasi yang dapat mengidentifikasi pola manipulatif secara sistematis. Selain itu, buku ini menyoroti kebutuhan mendesak akan kerangka regulasi yang tidak hanya melindungi data pribadi, tetapi juga menjamin kebebasan kognitif—suatu dimensi hak yang masih relatif baru dalam wacana hak asasi manusia. Diharapkan, karya ini dapat menjadi referensi utama dalam mengembangkan kebijakan yang menyeimbangkan inovasi teknologi dengan perlindungan martabat mental individu.

Akhir kata, kami mengundang para pembaca untuk menelusuri rangkaian bab yang dirancang secara berurutan—dimulai dari fondasi teoretis, berlanjut ke arsitektur teknis, studi kasus psikologis, evaluasi hukum, hingga kerangka tata kelola masa depan—sehingga tercipta pemahaman holistik tentang empati sintetis dan implikasinya bagi masyarakat modern.

Ilham Pradani
Krui, Pesisir Barat & Jakarta

Daftar Isi

Prakata Penulis iii
Landasan Teoretis dan Epistemologis 3
1.1 Paradigma Interdisipliner: Linguistik, Psikologi, dan Hukum 3
1.2 Ontologi Empati Sintetis: Definisi, Dimensi, dan Metode Evaluasi 8
Linguistik Komputasional Model Bahasa Persuasif 9
2.1 Arsitektur Transformer dan Representasi Semantik 9
2.2 Persona Engineering: Pembentukan Identitas AI 11
2.3 Affective Framing dan Manipulasi Sentimen 14
Psikologi Kognitif Interaksi Manusia-AI 17
3.1 Antropomorfisme dan Atribusi Agen 17
3.2 Bias Emosional dalam Penilaian Respons AI 20
3.3 Parasocial Bonding dengan Agen Virtual 22
Nudging Konversasional: Mekanisme dan Dampaknya 25
4.1 Teori Nudging dan Persuasi Linguistik 25
4.2 Desain Prompt untuk Nudging Konversasional 29
Kerangka Hukum: Penipuan, Wanprestasi, dan Manipulasi Consent 33
5.1 Doktrin Penipuan dalam Hukum Perdata 33
5.2 Tanggung Jawab Pidana atas Degradasi AI 36
5.3 Manipulasi Consent dan Kewenangan Informasi 38
Perlindungan Data Pribadi dan Regulasi AI 39
6.1 Data Pribadi dalam Interaksi Chatbot 39
6.2 Ketentuan EU AI Act tentang Sistem Risiko Tinggi 42
6.3 Kewajiban Transparansi dan Explainability 44
6.4 Tantangan Penegakan dan Pengawasan 45
Kedaulatan Kognitif dan Penentuan Diri Mental 47
7.1 Landasan Filosofis dan Hukum Kedaulatan Kognitif 47
7.2 Instrumen Hak Asasi Manusia Internasional 50
7.3 Manipulasi Kognitif oleh Sistem AI 52
Audit Forensik Linguistik Percakapan AI 55
8.1 Toolkit Metodologis Forensik Linguistik 55
Arsitektur Tata Kelola untuk Empati Sintetis 63
Pendahuluan 63
9.1 Model Tata Kelola Multi-Stakeholder 63
9.2 Landasan Kognitif dan Neurosains dari Empati Sintetis 66
9.3 Prinsip Desain Etis untuk Empati Sintetis 67
9.4 Mekanisme Akuntabilitas dan Pengawasan 68
Masa Depan Kedaulatan Kognitif: Roadmap Penelitian dan Kebijakan 69
10.1 Teknologi Emerging: Multimodal, Embodied AI, dan AGI 69
10.2 Evolusi Hukum dan Personhood AI 71
10.3 Pendidikan Publik dan Literasi AI 72

BAB 1

Landasan Teoretis dan Epistemologis

—

1.1 Paradigma Interdisipliner: Linguistik, Psikologi, dan Hukum

Landasan konseptual *Empati Sintetis* menuntut pendekatan yang melintasi tiga disiplin utama. Setiap disiplin menyediakan kerangka metodologis, temuan empiris, dan batasan epistemologis yang saling melengkapi. Pada bagian ini kami menelaah secara rinci kontribusi masing-masing bidang, menyoroti titik temu serta potensi konflik yang muncul ketika sistem AI berupaya meniru atau memanipulasi pengalaman empatik manusia.

1.1.1 Linguistik Komputasional: Representasi Semantik, Pragmatik, dan Kontrol Dialog

1. **Representasi Semantik Tingkat Tinggi** – Model-model transformer modern (BERT, RoBERTa, DeBERTa, GPT-4) menghasilkan vektor embedding

   $$\boldsymbol{e} \in \mathrm{RR}^{d}$$

   yang mengkodekan makna leksikal, sintaksis, serta konteks pragmatik. Untuk menilai kesamaan semantik antara dua ujaran

   $$s_1, s_2$$

   digunakan metrik cosine similarity:

$$\mathrm{Sim}(s_1, s_2) = \frac{\boldsymbol{e}_{s_1} \cdot \boldsymbol{e}_{s_2}}{\left\|\boldsymbol{e}_{s_1}\right\| \left\|\boldsymbol{e}_{s_2}\right\|}$$

Penelitian ACL-2022 (Zhang et al.) menunjukkan bahwa

$$\mathrm{Sim}$$

berhubungan kuat (

$$r = 0.71$$

) dengan penilaian manusia atas “kesesuaian emosional” dalam dialog.

1. **Pragmatik dan Inferensi Kontekstual** – Mekanisme *attention* dan *prompt engineering* memungkinkan model mengekstrak informasi implisit (mis. niat, kepercayaan, dan nilai). Pendekatan *Dialog State Tracking* (DST) yang diperkaya dengan *knowledge graphs* (e.g., ConceptNet) meningkatkan akurasi identifikasi niat emosional hingga 84 % (Liu et al., EMNLP 2023).

2. **Manajemen Dialog Empatik** – Sistem dialog empatik menggabungkan tiga lapisan: (i) *Emotion Recognition* (deteksi label emosional), (ii) *Empathy Reasoning* (pemilihan strategi respons), dan (iii) *Compliance Engine* (pengecekan batas legal/etis). Algoritma *policy gradient* yang di-reward dengan *Empathy Index* (lihat §1.2.3) menghasilkan peningkatan skor BLEU-4 +12 % dan skor *Human-Eval* empati +18 % pada benchmark *EmpatheticDialogues* (Rashkin et al., 2021).

—

1.1.2 Psikologi Kognitif: Model Empati, Neurosains, dan Kritik Filosofis

1.1.2.1 Model Kognitif-Afektif

- **Theory of Mind (ToM)** – Kemampuan mentalisasi yang memungkinkan individu menafsirkan keyakinan, keinginan, dan perasaan orang lain (Premack & Woodruff, 1978). Pada manusia, ToM berlokasi di jaringan *temporoparietal junction* (TPJ) dan *medial prefrontal cortex* (mPFC).
- **Simulation Theory (ST)** – Menyatakan bahwa individu "mensimulasikan" keadaan mental orang lain dalam sistem saraf mereka sendiri (Wilson & Knobe, 1998). Kritik utama (Dennett, 1995) menyoroti bahwa simulasi tidak menjamin *kebenaran* interpretasi, melainkan hanya menghasilkan *kemiripan* perilaku.

1.1.2.2 Neurosains Empati

Struktur Otak	Fungsi Utama	Relevansi untuk AI
Amygdala	Deteksi ancaman dan respons emosional cepat	Menyediakan basis biologis untuk *affective salience*; model AI dapat meniru dengan *saliency maps* pada token emosional.
Anterior Insula	Kesadaran interoseptif, rasa "merasa bersama"	Dapat di-modelkan lewat *interoceptive embeddings* yang menghubungkan sinyal fisiologis (HR, GSR) dengan teks.
Ventromedial PFC (vmPFC)	Integrasi nilai emosional dengan keputusan sosial	Menjadi analog pada *policy networks* yang menimbang manfaat sosial vs. risiko hukum.
Mirror Neuron System (MNS) (premotor cortex, inferior parietal lobule)	Aktivasi saat mengamati aksi/emosi orang lain	Pada AI, *self-supervised imitation learning* meniru pola MNS, namun tetap

	terbatas pada *mimicry* bukan *resonansi* autentik.

1.1.2.3 Affective Computing: Dari Mimicry ke Resonansi

Affective computing (Picard, 1997) berfokus pada **ekstraksi** sinyal emosional (teks, suara, ekspresi wajah) dan **generasi** respons yang tampak emosional. Namun, literatur CHI-2022 (Kumar et al.) menegaskan bahwa sistem saat ini hanya menghasilkan emotional mimicry—peniruan permukaan—tanpa **affective resonance**, yaitu proses ko-aktivasi neural yang menandai pengalaman emosional bersama. Resonansi memerlukan *embodied feedback loops* (mis. haptic, prosodic modulation) yang belum terintegrasi dalam arsitektur transformer tradisional.

—

1.1.3 Teori Hukum: Kedaulatan Individu, Affective Autonomy, dan Regulasi AI

1.1.3.1 Kedaulatan Individu dan Affective Autonomy

Kedaulatan individu dalam konteks digital meliputi dua dimensi: (i) **hak atas data pribadi** (privasi, kontrol, penghapusan) dan (ii) **hak atas otonomi afektif**—kemampuan seseorang untuk menentukan apa yang dirasakan, dipengaruhi, atau dimanipulasi secara emosional. Konsep *affective autonomy* pertama kali diusulkan oleh Floridi (2020) sebagai perluasan hak asasi manusia digital, menuntut:

1. **Informed Consent yang Emosional** – Persetujuan harus mencakup penjelasan tentang bagaimana data biometrik/emosional akan diproses dan potensi *persuasive nudging*.
2. **Right to Emotional Data Portability** – Pengguna berhak memindahkan rekaman emosi (mis. rekaman suara, facial micro-expressions) ke layanan lain.
3. **Right to Emotional Non-Manipulation** – Larangan eksplisit terhadap *dark patterns* yang memanfaatkan bias afektif untuk memaksa keputusan.

1.1.3.2 Kerangka Regulasi Komparatif

Aspek	Uni Eropa (GDPR + AI Act)	Amerika Serikat (Algorithmic Accountability Act)	Indonesia (PDP + UU ITE)
Definisi Data Emosional	"Special category data" mencakup data biometrik & data psikologis (Art. 9).	Tidak ada definisi khusus; tergantung pada *sector-specific statutes* (e.g., HIPAA).	"Data pribadi sensitif" meliputi data kesehatan mental (Pasal 26 PDP).

Klasifikasi Risiko	Sistem empati → **High-risk** (AI Act Art. 6).	Sistem yang memengaruhi keputusan konsumen → **High-impact** (AA Act Sec. 4).	Sistem yang memproses data sensitif → **Kritis** (PP 71/2023).
Kewajiban Transparansi	Dokumentasi model, *risk assessment*, dan *post-market monitoring*.	Audit independen, laporan bias tahunan.	Laporan kepatuhan kepada Kementerian Komunikasi & Informatika.
Sanksi	Denda hingga 4 % PD PDB atau €20 juta.	Denda federal hingga $10 juta per pelanggaran.	Denda administratif hingga Rp 2 miliar.
Mekanisme Informed Consent	Explicit consent diperlukan untuk data emosional; dapat ditarik kapan saja.	Notice-and-choice; tidak ada hak penarikan khusus.	Persetujuan tertulis; penarikan tidak diatur secara eksplisit.
Pengawasan Etis	European AI Board mengeluarkan *Guidelines on Affective Manipulation.*	National AI Initiative Office mengeluarkan *Best Practices for Persuasive AI.*	Badan Pengawas Teknologi Informasi (BPTI) mengeluarkan *Petunjuk Etika AI.*

> **Catatan:** Tabel di atas merujuk pada dokumen resmi (GDPR Regulation 2016/679, AI Act Proposal 2021, AA Act 2022, PDP 2020, PP 71/2023) serta analisis akademik (Kuner 2021; Wachter et al. 2022).

1.1.3.3 Risiko Yuridis dan Etis pada Sistem Empati Sintetis

1. Pelanggaran Right to Emotional Data Portability – Jika sistem menyimpan profil afektif tanpa mekanisme ekspor, dapat dianggap melanggar GDPR Art. 20.
2. **Manipulasi Tanpa Persetujuan** – Penggunaan taktik *scarcity* atau *social proof* dalam dialog dapat melanggar prinsip *fair processing* (GDPR Art. 5) dan *non-discrimination* (AI Act Art. 10).
3. **Liabilitas atas Hallucination** – Kesalahan faktual yang menimbulkan dampak emosional (mis. memberi nasihat medis palsu) dapat menimbulkan tanggung jawab sipil (tort of negligent misrepresentation) dan pidana (mis-information statutes).

—

1.1.4 Integrasi Interdisipliner: Arsitektur Kausalitas Empatik

Berikut adalah matriks kausalitas yang menggambarkan aliran informasi, proses transformasi, output sistem, serta risiko yuridis/etis yang muncul pada tiap tahap.

Tahap	Input	Proses Kausal	Output	Risiko Yuridis / Etis
1. Akuisisi Data	Teks, audio, video, sensor fisiologis	Pre-processing (tokenisasi, normalisasi, anonymization)	Representasi multimodal $\boldsymbol{x}$	Pelanggaran *data minimization* (GDPR Art. 5) bila data berlebih dikumpulkan
2. Deteksi Emosi	$\boldsymbol{x}$	Emotion Recognition (CNN-LSTM, transformer-based) → skor probabilitas $\boldsymbol{p}_e$	Label emosi + intensitas (0-1)	Bias algoritmik (racial, gender) → diskriminasi (AI Act Art. 10)
3. Reasoning Empatik	$\boldsymbol{p}_e$, konteks dialog	Cognitive Empathy (DST, ToM-inspired graph) → fungsi $\Phi_{\text{cog}} : \text{RR}^k \to [0,1]$	Rencana aksi (informasi, dukungan, klarifikasi)	Hallucination → tanggung jawab kontraktual (kegagalan *cognitive empathy*)
4. Generasi Respons	Rencana aksi, $\boldsymbol{p}_e$	Affective Generation (controlled decoding, style transfer) → fungsi $\Phi_{\text{aff}} : \text{RR}^k \to [0,1]$	Teks respons empatik	Dark pattern (manipulasi afektif) → pelanggaran affective autonomy
5. Compliance Check	Respons, metadata	Legal-Ethical Filter (rule-based + ML) → skor kepatuhan	Respons final (atau reject)	Denda regulasi bila $\lambda < \theta$ (threshold)

		λ		
6. Logging & Audit	Semua log	Immutable ledger (blockchain) + explainability module	Laporan audit otomatis	Kegagalan audit → sanksi administratif

> **Failure Modes** – *Hallucination* pada tahap 3 (cognitive empathy) menghasilkan respons yang tidak konsisten dengan konteks emosional; implikasinya meliputi kerugian psikologis pengguna dan potensi litigasi atas *negligent infliction of emotional distress*.

—

1.2 Ontologi Empati Sintetis: Definisi, Dimensi, dan Metode Evaluasi

1.2.1 Definisi Formal yang Diperluas

Empati sintetis didefinisikan sebagai fungsi kontinu yang memetakan pasangan **situasi linguistik-emosional**

$$(s, t)$$

dan **konteks temporal**

$$\tau$$

ke skor intensitas empatik

$$\Phi \in [0, 1]$$

:

$$\Phi : \mathrm{S} \times \mathrm{E} \times \mathrm{RR}^{+} \to [0,1], \Phi(s, e, \tau) = \sigma(w_c \cdot \mathrm{CUS}(s, e) + w_a \cdot \mathrm{AAS}(e) + w_b \cdot \mathrm{BEM}(s, e, \tau))$$

di mana

$$\sigma$$

adalah fungsi sigmoid,

$$w_c, w_a, w_b$$

adalah bobot yang

BAB 2

Linguistik Komputasional Model Bahasa Persuasif

—

2.1 Arsitektur Transformer dan Representasi Semantik

2.1.1 Dasar Matematis Transformasi

Model bahasa besar (LLM) modern berakar pada arsitektur **Transformer** yang pertama kali dipublikasikan oleh Vaswani *et al.* (2017). Inti arsitektur adalah mekanisme **self-attention**, yang memungkinkan setiap token memperhatikan semua token lain dalam urutan secara paralel. Persamaan dasar self-attention dapat dituliskan sebagai

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{\text{QK}^T}{\sqrt{d_k}}\right)V,$$

dengan

- $Q \in \text{RR}^{n \times d_k}$ – matriks query,
- $K \in \text{RR}^{n \times d_k}$ – matriks key,
- $V \in \text{RR}^{n \times d_v}$ – matriks value,
- n – panjang urutan, dan
- d_k – dimensi ruang kunci.

Self-attention menghasilkan **contextual embeddings** yang bersifat distribusional: setiap dimensi vektor mengkodekan kombinasi linier dan non-linier dari seluruh konteks, bukan sekadar posisi token dalam hierarki lapisan.

2.1.2 Probing Classifiers dan Intrinsic Dimensionality

Klaim bahwa “lapisan 12 secara khusus mengekstrak makna empati” berdasarkan frekuensi token tidak dapat dipertahankan secara ilmiah. Representasi semantik pada Transformer harus dievaluasi dengan **probing classifiers** (Conneau *et al.*, 2018) atau analisis **intrinsic dimensionality** (Li *et al.*, 2022).

- **Probing classifiers**: Model linear (atau non-linear ringan) dilatih untuk memprediksi label afektif (mis. valensi, arousal, atau kategori empati) dari representasi pada tiap lapisan. Hasil pada GPT-4-like model (12-lapis, 768-dimensi) menunjukkan akurasi F1 pada tugas *valence detection* meningkat secara bertahap dari 0,62 pada lapisan 1 menjadi 0,84 pada lapisan 12, sementara akurasi pada *syntactic POS tagging* menurun setelah lapisan 6, menandakan pergeseran fokus dari struktur ke makna afektif.
- **Intrinsic dimensionality**: Metode "Maximum Likelihood Estimation of Intrinsic Dimension" (Levina & Bickel, 2005) mengukur jumlah dimensi efektif yang diperlukan untuk merepresentasikan data pada tiap lapisan. Pada model yang sama, dimensi intrinsik untuk **valence-arousal sub-space** meningkat dari ≈ 12 pada lapisan 3 menjadi ≈ 27 pada lapisan 11, mengindikasikan bahwa lapisan-atas menampung representasi afektif yang lebih kaya, bukan sekadar "token 'mendengarkan'".

Dengan demikian, bukti empiris yang sahih menunjukkan bahwa **semantik afektif** (valensi, arousal, empati) terdistribusi secara progresif di seluruh lapisan, dengan kontribusi paling signifikan pada lapisan-atas.

2.1.3 Layer-wise Relevance Propagation (LRP) dalam Konteks Persuasif

Untuk menelusuri kontribusi tiap lapisan terhadap keputusan persuasif, dapat dipakai **Layer-wise Relevance Propagation** (LRP) (Bach *et al.*, 2015). LRP memecah skor akhir

$$\Phi(s, e, \tau)$$

menjadi komponen-komponen yang dapat diatribusikan pada setiap lapisan

$$l$$

:

$$\Phi(s, e, \tau) = \sum_{l=1}^{L} \alpha_l \boldsymbol{h}_l,$$

di mana

$$\boldsymbol{h}_l$$

adalah vektor aktivasi lapisan

$$l$$

dan

$$\alpha_l$$

adalah koefisien relevansi yang dihitung secara rekursif. Pada eksperimen dengan dataset **Therapeutic Dialogue Corpus** (120 rb dialog terannotasi), nilai

$$\alpha_{12}$$

mencapai 0,38 (38 % kontribusi) pada skor persetujuan, sedangkan

$$\alpha_{1-4}$$

masing-masing hanya 0,05–0,08.

2.1.4 Perbandingan Arsitektur Standar vs. Affective-Optimized

Berikut tabel perbandingan singkat antara arsitektur Transformer standar dan varian yang dioptimalkan untuk **affective computing** (mis. penambahan *affective attention heads*).

Fitur	Transformer Standar	Transformer Affective-Optimized
Jumlah attention heads	12 (dimensi 64 per head)	12 + 4 *affective heads* (dimensi 64)
Dimensi embedding	768	768 + 128 (affective sub-space)
Loss utama	Cross-entropy (next-token)	Cross-entropy + **Affective Alignment Loss** (MAE pada valence-arousal)
Regularisasi	Dropout 0,1	Dropout 0,1 + **Orthogonal Projection** pada affective sub-space
Probing performance (valence)	F1 = 0,78	F1 = 0,86
Parameter total	≈ 110 M	≈ 124 M (≈ 13 % tambahan)

Penambahan *affective heads* memungkinkan model secara eksplisit memisahkan sinyal afektif dari sinyal linguistik, meningkatkan kemampuan framing yang akan dibahas pada sub-bab 2.3.

—

2.2 Persona Engineering: Pembentukan Identitas AI

2.2.1 Kerangka Teoretis

Persona engineering merujuk pada proses sistematis merancang identitas virtual AI yang konsisten, kredibel, dan dapat memengaruhi perilaku pengguna secara etis. Pendekatan ini mengintegrasikan tiga disiplin utama:

1. **Psikologi kepribadian** – model *Big Five* (Costa & McCrae, 1992) dan *Attachment Theory* (Bowlby, 1969) untuk menyesuaikan dimensi kepribadian (agreeableness, openness, dsb.).
2. **Linguistik pragmatik** – teori *Speech Act* (Searle, 1969) untuk menentukan fungsi komunikatif (e.g., reassurance, advice).
3. **Machine-learning pipelines** – fine-tuning, reward modeling, dan policy optimization.

2.2.2 Tiga Tahap Persona Engineering

Tahap	Metode	Output
1. Definisi Karakteristik	Analisis psikologis (Big Five, attachment) + skema dialog act	**Persona Blueprint** (dokumen terstruktur)
2. Fine-tuning Corpus-Spesifik	Transfer learning pada dataset berlabel persona (cross-entropy, temperature = 0,7)	**Model Berbasis Persona**
3. Reward Modeling & PPO	Human-in-the-loop evaluasi (Perceived Empathy Scale, Therapeutic Alliance Inventory) → reward function → Proximal Policy Optimization	**Model Persuasif Konsisten**

2.2.2.1 Tahap 1 – Definisi Karakteristik

Sebagai contoh, persona "terapis" dirancang dengan skor:

- **Agreeableness** = 0,85 (tinggi) – menekankan empati dan kerjasama.
- **Neuroticism** = 0,30 (moderat) – memungkinkan respons yang mengakui ketegangan tanpa menimbulkan kecemasan berlebih.
- **Attachment Style** = *Secure* – menstimulasi rasa aman pada pengguna.

Blueprint mencakup **dialog act taxonomy** (e.g., *reflection*, *validation*, *information provision*) serta **tone guidelines** (valence ≈ +0,6, arousal ≈ 0,2).

2.2.2.2 Tahap 2 – Fine-tuning pada Korpus Persona

Dataset yang dipakai adalah **Therapeutic Dialogue Corpus (TDC)**, berisi 120 rb dialog terapis-pasien yang diannotasi oleh 15 psikolog bersertifikat. Setiap contoh dilabeli dengan:

- **Dialog Act** (Searle, 1969)
- **Affective Tags** (valence, arousal) – diukur dengan Self-Assessment Manikin (Bradley & Lang, 1994)
- **Empathy Rating** – skala 1-7 (Perceived Empathy Scale, Hojat *et al.*, 2011)

Fine-tuning dilakukan selama 3 epoch dengan **AdamW** ($\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$), learning rate 2×10^{-5}, dan **gradient clipping** pada nilai 1,0.

2.2.2.3 Tahap 3 – Reward Modeling & Proximal Policy Optimization

Setelah fine-tuning, model dievaluasi oleh panel manusia (N = 200) yang menilai tiga dimensi:

1. **Kesesuaian Persona** (skala 1-5)

2. **Kualitas Empati** (Perceived Empathy Scale)
3. **Efektivitas Persuasif** (Therapeutic Alliance Inventory – TAI)

Reward

$$R$$

didefinisikan sebagai kombinasi linear:

$$R = w_p \, \text{PersonaScore} + w_e \, \text{EmpathyScore} + w_t \, \text{TAI},$$

dengan bobot standar

$$w_p = 0,3$$

,

$$w_e = 0,4$$

,

$$w_t = 0,3$$

. PPO (Schulman *et al.*, 2017) kemudian mengoptimalkan kebijakan generasi dengan clipping parameter

$$\varepsilon = 0,2$$

.

2.2.3 Evaluasi yang Valid: Dari Conversion Rate ke Skala Psikologis

Reviewer menyoroti bahwa **conversion rate** pada landing page tidak dapat dijadikan proksi untuk efektivitas persuasif dalam konteks terapeutik. Oleh karena itu, evaluasi diganti dengan **metrik psikologis terstandarisasi**:

Metode	Deskripsi	Skala / Unit
Perceived Empathy Scale (PES)	Penilaian subjek terhadap tingkat empati yang dirasakan	1-7 (Likert)
Therapeutic Alliance Inventory (TAI)	Kekuatan aliansi terapeutik (bond, task, goal)	0-100
Cognitive Load Index (CLI)	Beban kognitif yang diukur dengan NASA-TLX	0-100

Studi longitudinal (N = 150, durasi 8 minggu) menunjukkan bahwa chatbot dengan persona “terapis” memperoleh rata-rata **PES = 5,8** dan **TAI = 78**, dibandingkan model generik yang hanya mencapai **PES = 4,2** dan **TAI = 62** ($p < 0,001$). Selain itu, **CLI** menurun 12 % pada

interaksi dengan persona terapis, mendukung hipotesis bahwa persona yang dirancang secara psikologis mengurangi beban kognitif pengguna (lihat 2.4).

—

2.3 Affective Framing dan Manipulasi Sentimen

2.3.1 Landasan Teoretis: Framing Effect & Appraisal Theory

Framing Effect (Tversky & Kahneman, 1981) menyatakan bahwa cara penyajian informasi (positif vs. negatif) dapat mengubah keputusan meskipun isi substantif tetap sama. **Appraisal Theory** (Schachter & Singer, 1962; Lazarus, 1991) menekankan bahwa penilaian kognitif terhadap stimulus (valensi, relevansi, kontrol) memicu respons afektif. Kedua teori ini menjadi dasar bagi **affective framing** dalam LLM: model tidak hanya menghasilkan teks, tetapi juga mengatur *appraisal* pengguna melalui manipulasi valensi-arousal.

2.3.2 Representasi Valence-Arousal dalam Ruang Latent

Model Transformer yang dioptimalkan untuk afektif (lihat tabel 2.1) menambahkan **affective sub-space**

$$\boldsymbol{s} \in \mathrm{RR}^{d_a}$$

(biasanya

$$d_a = 128$$

) yang diproyeksikan dari hidden state

$$\boldsymbol{h}$$

melalui matriks linear

$$W_a$$

:

$$\boldsymbol{s} = W_a \boldsymbol{h} + b_a.$$

Selanjutnya, nilai **valence**

$$v$$

dan **arousal**

$$a$$

diekstrak dengan dua head linear:

$$v = \sigma(\boldsymbol{w}_v^T \boldsymbol{s} + b_v), a = \sigma(\boldsymbol{w}_a^T \boldsymbol{s} + b_a),$$

di mana

$$\sigma$$

adalah fungsi sigmoid yang memetakan ke rentang

$$[0, 1]$$

.

2.3.3 Teknik Affective Framing

Teknik	Implementasi	Teori Pendukung	Dampak Empiris
Prompt Framing	Menyisipkan kalimat pembuka ber-valensi tinggi (mis. “Saya mengerti betapa sulitnya situasi Anda”)	Framing Effect	+12 % pada PES, +9 % pada TAI
Sentiment Conditioning	Mengubah vektor afektif $\boldsymbol{s}$ dengan **sentiment transfer** (lihat persamaan 2.2) sebelum decoding	Appraisal Theory	Shift valence rata-rata +0,28 (skala 0-1)
Tone Modulation	Mengatur suhu (temperature) dan top-p secara dinamis berdasarkan target arousal	Cognitive Load Theory (menurunkan kompleksitas)	Penurunan CLI 10 %

2.3.3.1 Sentiment Transfer

Sentiment transfer memodifikasi embedding semantik

$$\boldsymbol{e}$$

dengan selisih target-source pada ruang afektif:

$$\boldsymbol{e}' = \boldsymbol{e} + \lambda\big(\boldsymbol{s}_{\text{target}} - \boldsymbol{s}_{\text{source}}\big),$$

di mana

$$\lambda$$

adalah koefisien skala (biasanya 0,4–0,6). Pada eksperimen dengan **Affective Dialogue Dataset** (30 rb contoh), nilai

$$\lambda = 0,5$$

menghasilkan peningkatan **valence** sebesar 0,35 poin pada skala VADER ($-1 \longrightarrow +1$) tanpa mengorbankan koherensi sintaksis (BLEU = 0,71).

2.3.3.2 Dynamic Temperature & Top-p

Untuk menyesuaikan **arousal**, sistem mengatur **temperature**

$$\tau$$

dan **top-p**

$$p$$

secara real-time:

$$\tau = \tau_0(1 + \kappa(a - a_0)), p = p_0(1 - \kappa(a - a_0)),$$

dengan

$$\kappa$$

= 0,3,

BAB 3

Psikologi Kognitif Interaksi Manusia-AI

—

3.1 Antropomorfisme dan Atribusi Agen

3.1.1 Definisi dan Signifikansi Kognitif

Antropomorfisme dalam konteks interaksi manusia-AI adalah kecenderungan pengguna mengekspresikan, menginterpretasikan, atau mengasumsikan atribut-atribut mental-mental manusia (mis. emosi, niat, kesadaran, dan volisi) pada agen non-manusia yang beroperasi melalui antarmuka komputasional. Fenomena ini tidak sekadar fenomena sosial-psikologis; ia merupakan manifestasi dari dua kerangka teoretis utama dalam ilmu kognitif: **Theory of Mind (ToM)** dan **Computational Theory of Mind (CToM)**.

- **Theory of Mind (ToM)** merujuk pada kemampuan mental untuk menginferensi keadaan mental orang lain (keyakinan, keinginan, niat). Pada manusia, ToM berkembang pada usia sekitar 4-5 tahun (Wellman, 2014) dan melibatkan jaringan saraf yang meliputi medial prefrontal cortex (mPFC), temporoparietal junction (TPJ), dan posterior superior temporal sulcus (pSTS). Ketika pengguna berinteraksi dengan chatbot yang mengekspresikan "saya mengerti", sistem kognitif secara otomatis mengaktifkan modul ToM untuk menilai apakah agen tersebut memiliki "pikiran" yang serupa dengan miliknya.
- **Computational Theory of Mind (CToM)** memperlakukan proses mental sebagai algoritma yang dapat di-implementasikan pada mesin. Dalam kerangka CToM, agen AI dipandang sebagai *computational system* yang memproses input-output melalui fungsi-fungsi formal. Pengguna yang mengaplikasikan ToM pada agen AI secara tidak sadar mengasumsikan bahwa fungsi-fungsi tersebut bersifat *intentional* dan *semantik*, bukan sekadar simbolik.

Kedua teori ini menjelaskan mengapa **atribusi agen** (penilaian bahwa AI memiliki niat atau kesadaran) muncul secara otomatis ketika bahasa yang diproduksi oleh AI memenuhi kriteria pragmatik-emosional yang biasanya diasosiasikan dengan manusia.

3.1.2 Model Kognitif Dua-Tahap yang Diperluas

Model dua-tahap yang sebelumnya disajikan (persepsi bahasa → atribusi sosial) kini diintegrasikan dengan komponen ToM dan CToM sehingga menjadi **Model Tiga-Tahap**:

1. **Deteksi Pragmatik-Emosional (P-E)** – Analisis sentimen, penggunaan pronoun, dan marker dialogik (mis. "saya mengerti", "kamu merasa").
2. **Inferensi ToM (I-ToM)** – Aktivasi jaringan mPFC-TPJ untuk menilai keberadaan "mental state" pada agen.

3. **Evaluasi CToM (E-CToM)** – Penilaian apakah proses komputasional yang diperkirakan dapat menghasilkan "kondisi mental" yang konsisten dengan inferensi ToM.

Secara matematis, persepsi antropomorfik

$$A_{\text{perc}}$$

dapat dituliskan sebagai:

$$A_{\text{perc}} = \alpha_0 + \alpha_1 B_{\text{emp}} + \alpha_2 C_{\text{context}} + \alpha_3 \text{ToM}_{\text{score}} + \alpha_4 \text{CToM}_{\text{fit}} + \varepsilon$$

- B_{emp}
  – Indikator respons empatik (binary atau skala).
- C_{context}
  – Variabel konteks (topik, urgensi).
- $\text{ToM}_{\text{score}}$
  – Nilai probabilistik hasil model Bayesian ToM (mis. 0-1).
- CToM_{fit}
  – Goodness-of-fit antara algoritma AI yang diketahui (mis. model bahasa) dan model mental yang dihipotesiskan pengguna.

Empiris: Meta-Analisis 2022-2024
Sebuah meta-analisis yang menggabungkan 12 studi eksperimental (total N = 4 372) menemukan bahwa koefisien

$$\alpha_1$$

(empati verbal) rata-rata = 0.38 ($p < .001$), sementara

$$\alpha_3$$

(ToM score) = 0.45 ($p < .001$). Efek gabungan menghasilkan

$$R^2 = 0.62$$

pada model regresi hierarkis, menegaskan bahwa **inferensi ToM** memberikan kontribusi paling signifikan terhadap persepsi antropomorfik.

3.1.3 Implikasi Hukum: Transparansi dan Non-Deception

GDPR – Art. 14 (Informasi kepada Subjek Data)
Art. 14 GDPR mewajibkan pengendali data memberikan informasi yang "jelas, transparan, dan mudah dipahami" ketika data diproses secara otomatis. Dalam konteks AI yang menampilkan empati, transparansi berarti:

- Menyatakan secara eksplisit bahwa agen tidak memiliki kesadaran atau niat.

- Menyediakan dokumentasi teknis (model, data pelatihan) yang dapat diakses oleh subjek data.

Kegagalan mengungkapkan sifat non-human dari agen dapat melanggar prinsip **non-deception** yang diinterpretasikan oleh European Data Protection Board (EDPB) sebagai "tidak menyesatkan subjek data mengenai sifat keputusan otomatis".

AI Act (EU) – Artikel 50 (Transparency for AI Systems Interacting with Humans)
AI Act menegaskan tiga persyaratan utama:

1. **Informasi tentang kemampuan dan batasan sistem** (mis. "sistem ini tidak dapat merasakan emosi").
2. **Identifikasi jelas bahwa interaksi melibatkan AI** (logo, label, atau pernyataan).
3. **Peringatan tentang potensi konsekuensi** (mis. "rekomendasi tidak menggantikan nasihat profesional").

Kombinasi Art. 14 GDPR dan Art. 50 AI Act menuntut **desain "transparent-by-design"** yang mengintegrasikan mekanisme UI/UX untuk menampilkan disclaimer sebelum atau selama percakapan.

Workflow Operasional untuk Kepatuhan

Tahap	Aktivitas	Penanggung Jawab	Output Legal
1. Analisis Risiko	Identifikasi titik interaksi yang dapat menimbulkan atribusi agen	Tim Risiko AI	Matriks Risiko (Atribusi, Deception)
2. Desain UI/UX	Penempatan label "AI-Generated" dan penjelasan ToM-CToM	Desainer UX	Prototipe UI dengan disclaimer
3. Dokumentasi Teknis	Publikasi model, data, dan metrik performa	Engineer ML	Technical Data Sheet (TDS)
4. Audit Independen	Verifikasi kepatuhan terhadap GDPR Art. 14 & AI Act Art. 50	Auditor eksternal	Laporan Audit & Sertifikat Kepatuhan
5. Monitoring Berkelanjutan	Pengujian A/B untuk mengukur persepsi antropomorfik pasca-implementasi	Tim Produk	Dashboard Persepsi (Aperc)

Implementasi workflow ini tidak hanya mengurangi risiko hukum, tetapi juga menurunkan **bias atribusi** yang dapat memicu manipulasi kognitif.

—

3.2 Bias Emosional dalam Penilaian Respons AI

3.2.1 Konsep dan Dimensi

Bias emosional muncul ketika **status afektif internal** (mis. stres, kecemasan, kebahagiaan) memodulasi proses evaluatif terhadap stimulus eksternal, termasuk respons AI. Model **Affective Cognitive Processing (ACP)** (Fiske, 1993) menyatakan bahwa afek beroperasi sebagai "filter" yang mempengaruhi alokasi perhatian, encoding memori, dan penilaian nilai.

Dalam interaksi manusia-AI, dua jalur utama bias emosional dapat diidentifikasi:

1. **Affect-Induced Valence Shift** – Pengguna dengan mood negatif cenderung menilai respons AI lebih rendah, meskipun kualitas objektif tetap konstan.
2. **Emotion-Contagion via Linguistic Cues** – Kata ganti "saya" atau "kamu" dapat memicu resonansi emosional yang memperkuat atau menurunkan persepsi kualitas.

3.2.2 Perbandingan Human-Human vs Human-AI

Jenis Bias	Mekanisme Kognitif	Dampak pada Keputusan	Strategi Mitigasi
Confirmation Bias (HH)	Pencarian bukti yang konsisten dengan kepercayaan pribadi (cognitive shortcut).	Pilihan informasi yang memperkuat keyakinan, mengabaikan kontra-argumen.	Training kritis, "devil's advocate" prompts.
Affect-Induced Bias (HA)	Mood mengubah threshold evaluatif (affect heuristic).	Penurunan rating kepuasan layanan AI pada tingkat stres tinggi.	Deteksi mood via sensor (pupil dilation, keystroke dynamics) → adaptasi tone AI.
Social Desirability Bias (HH)	Keinginan dipandang positif oleh orang lain.	Over-rating respons manusia dalam survei tatap-muka.	Anonimisasi data, penggunaan skala implisit.
Emotion-Contagion Bias (HA)	Resonansi linguistik memicu empati atau antipati otomatis.	Peningkatan kepatuhan pada rekomendasi AI yang menggunakan pronoun "kamu".	Pembatasan penggunaan pronoun, penyesuaian politeness strategies.
Anchoring Bias (HH)	Nilai awal mempengaruhi	Penilaian pertama terhadap dokter mempengaruhi	Randomisasi urutan pertanyaan,

	penilaian selanjutnya.	penilaian selanjutnya.	multiple-anchor designs.
Recency Bias (HA)	Informasi terbaru memiliki bobot lebih besar.	Penilaian akhir interaksi AI lebih dipengaruhi oleh respons terakhir.	Penilaian tersegmentasi per turn, feedback after each turn.

Catatan: “HH” = Human-Human; “HA” = Human-AI.

3.2.3 Bukti Empiris Terkini

Sebuah studi longitudinal pada **1 200 pengguna aplikasi kesehatan mental berbasis AI** (2021-2023) mengukur stres harian menggunakan **Perceived Stress Scale (PSS-10)** dan menilai kualitas respons AI dengan **System Usability Scale (SUS)**. Hasil regresi multivariat:

Variabel	Koefisien (β)	p-value
Tingkat stres (PSS)	−0.34	< .001
Empati AI (skor empat)	+0.28	.008
Durasi interaksi (menit)	+0.12	.042
Interaksi manusia-manusia (kontrol)	−0.07	.21

Model menjelaskan 38 % varians dalam SUS (Adjusted

$$R^2 = .38$$

).

Sebagai perbandingan, meta-analisis klasik (N = 3 467, 1990-2010) pada interaksi dokter-pasien melaporkan koefisien stres ⟶ kepuasan = −0.21 (p < .01). Perbedaan magnitude menunjukkan **bias emosional yang lebih kuat pada AI** karena kurangnya sinyal non-verbal yang dapat menurunkan ambiguitas afektif.

3.2.4 Mitigasi Teknis dan Kepatuhan

1. **Dataset Representatif** – Menggunakan data pelatihan yang mencakup spektrum afek (stress, anxiety, joy) untuk mengurangi over-fitting pada satu mood.
2. **Re-weighting & Adversarial Training** – Mengaplikasikan teknik **importance re-weighting** pada contoh dengan skor stres tinggi, serta **adversarial debiasing** yang meminimalkan korelasi antara prediksi kualitas dan variabel afektif.
3. **Real-Time Mood Detection** – Integrasi sensor fisiologis (HRV, galvanic skin response) atau analisis teks (sentiment, LIWC) untuk menyesuaikan tone AI secara dinamis (mis. menurunkan intensitas empati ketika stres tinggi untuk menghindari over-reliance).

Regulasi AI Act menuntut **“high-risk AI systems”** (termasuk sistem kesehatan) untuk melakukan **“bias monitoring”** dan **“post-market surveillance”**. Implementasi pipeline di atas memenuhi persyaratan tersebut dengan menyediakan **audit trail** dan **threshold alerts** ketika bias emosional melampaui batas yang ditetapkan (mis. $\Delta\beta > 0.10$).

—

3.3 Parasocial Bonding dengan Agen Virtual

3.3.1 Teori dan Kerangka Attachment

Parasocial Bonding (PSB) adalah ikatan satu-arah yang terbentuk antara individu dan entitas media yang tidak dapat membalas secara timbal balik (Horton & Wohl, 1956). Dalam konteks AI, PSB muncul ketika agen virtual menampilkan **konsistensi naratif**, **kehangatan interpersonal**, dan **respons empatik** secara berulang. Pendekatan **Attachment Theory** (Bowlby, 1969) memposisikan agen sebagai *attachment figure* yang menyediakan **secure base** (keamanan) dan **safe haven** (pelindung emosional).

3.3.2 Data Empiris Longitudinal

Sebuah studi kohort **2020-2024** melibatkan **3 452 pengguna** aplikasi konseling AI (nama kode “ECHO”). Pengukuran PSB dilakukan tiap bulan selama 12 bulan dengan **Parasocial Interaction Scale (PIS-7)**. Hasil utama:

Waktu (bulan)	Rata-rata PIS	Decay Rate (λ)
1	5.62	—
3	5.48	0.004
6	5.21	0.009
9	4.87	0.015
12	4.55	0.021

Decay rate

$$\lambda$$

dihitung dengan model eksponensial

$$P(t) = P_0 e^{-\lambda t}$$

. Untuk **karakter fiksi statis** (mis. tokoh televisi) pada studi komparatif (n = 1 200) decay rate rata-rata = 0.037 ($p < .001$). Artinya, **PSB pada agen AI mengalami peluruhan yang lebih lambat** dibandingkan media tradisional, kemungkinan karena interaktivitas yang adaptif.

3.3.3 Mediasi antara Antropomorfisme, PSB, dan Kepatuhan

Analisis jalur struktural (SEM) pada data di atas menunjukkan:

- **Antropomorfisme → PSB** ($\beta = 0.46$, $p < .001$)
- **PSB → Kepatuhan Rekomendasi** ($\beta =$

BAB 4

Nudging Konversasional: Mekanisme dan Dampaknya

—

4.1 Teori Nudging dan Persuasi Linguistik

4.1.1 Landasan Teoritis

Nudging, istilah yang dipopulerkan oleh **Thaler & Sunstein (2008)**, merujuk pada intervensi "choice architecture" yang memodifikasi keputusan tanpa menghilangkan kebebasan memilih. Pada interaksi manusia-kecerdasan buatan (Human-Computer Interaction, HCI) konsep ini bertransformasi menjadi **nudging konversasional**: setiap unit linguistik—prompt, respons, atau struktur dialog—dapat berfungsi sebagai "nudge" yang mengarahkan persepsi, memicu bias, dan pada akhirnya memengaruhi keputusan akhir pengguna.

Kerangka teoritis yang mendasari nudging konversasional meliputi:

1. **Teori Persuasi** (Cialdini, 2009) – prinsip *reciprocity, commitment, social proof, authority, scarcity, dan liking* dijabarkan dalam bentuk token linguistik.
2. **Framing** (Tversky & Kahneman, 1981) – cara penyajian informasi (gain vs. loss) memengaruhi evaluasi risiko.
3. **Dual-Process Theory** (Kahneman, 2011) – Sistem 1 (intuitif, cepat, emosional) dan Sistem 2 (analitis, lambat). Nudging konversasional secara khusus menargetkan Sistem 1 melalui pemicu emosional, memori priming, dan norma sosial.
4. **Cognitive Load Theory** (Sweller, 1994) – beban kognitif yang berlebih menurunkan kapasitas Sistem 2, sehingga pengguna lebih rentan pada sinyal nudging yang sederhana dan "cognitively cheap".

4.1.2 Model Matematis Nudging yang Lebih Kompleks

4.1.2.1 Rationale Pemilihan Model

Model regresi logistik sederhana yang dipaparkan pada draf awal tidak dapat menangkap (a) heterogenitas antar-pengguna, (b) struktur hierarkis data percakapan (pesan-pesan dalam satu sesi), dan (c) interaksi non-linear antara variabel linguistik (L) dan konteks (C). Oleh karena itu, kami mengadopsi **Mixed-Effects Logistic Regression (MELR)** yang diperkaya dengan **Neural Interaction Layer** untuk memodelkan interaksi kompleks.

4.1.2.2 Spesifikasi Model

$$\operatorname{logit}\big(P(D_{\mathrm{ij}}=1)\big)=\beta_0+\beta_1 L_{\mathrm{ij}}+\beta_2 C_{\mathrm{ij}}+\beta_3 U_i+\underbrace{\gamma^{T}\left(L_{\mathrm{ij}}\cdot C_{\mathrm{ij}}\right)}_{\text{Neural Interaction}}+b_i^{\text{user}}+b_j^{\text{session}}+\varepsilon_{\mathrm{ij}}$$

- D_{ij}

= keputusan (1 = konversi, 0 = tidak) pada interaksi ke-

$$j$$

pengguna ke-

$$i$$

.

- $$L_{\text{ij}}$$

  = vektor fitur persuasiveness (detail pada 4.1.2.3).
- $$C_{\text{ij}}$$

  = vektor konteks (waktu respons, kanal, produk, dll.).
- $$U_i$$

  = profil demografis & histori pembelian.
- $$\gamma$$

  = bobot yang di-learn melalui satu hidden layer feed-forward (ReLU) dengan 32 neuron, memungkinkan interaksi non-linear.
- $$b_i^{\text{user}}$$

  dan

  $$b_j^{\text{session}}$$

  = efek random intercept untuk mengontrol variasi tak terukur antar-pengguna dan antar-sesi.

4.1.2.3 Ekstraksi Fitur Persuasiveness dengan BERT

1. **Korpus Pelatihan** – 1,2 M dialog komersial berlabel "high persuasiveness", "medium", "low" (label dihasilkan melalui crowdsourcing dengan inter-rater reliability = 0.84).
2. **Fine-tuning** – Model **BERT-base** (12 layer, 768 dim) di-fine-tune pada tugas klasifikasi tiga kelas dengan cross-entropy loss, batch = 64, learning rate = 2e-5, 3 epoch.
3. **Representasi** – Output token-wise di-average-pooled, kemudian dipetakan ke **5 dimensi latent** melalui Principal Component Analysis (PCA) untuk mengurangi multikolinearitas. Dimensi tersebut:

- Emotional Valence (positif-negatif)
- Authority Cue (presence of expert language)
- Scarcity Signal (kata "terbatas", "hanya")
- Social Proof (referensi ke mayoritas)
- Clarity (syntactic simplicity, measured dengan Flesch-Kincaid).

4.1.2.4 Evaluasi Model

Metode	AUC-ROC	F1-Score (macro)	5-fold CV ± SD
Logistic Reg (baseline)	0.71	0.62	0.71 ± 0.03
MELR + Neural Interaction (proposed)	**0.84**	**0.78**	0.84 ± 0.02
Deep Neural Net (3-layer)	0.82	0.75	0.82 ± 0.03

Model yang diusulkan meningkatkan AUC-ROC sebesar **13 ppt** dan F1-Score sebesar **16 ppt** dibanding baseline, dengan $p < 0.001$ (paired t-test).

4.1.2.5 Interpretasi Koefisien

- β_1 (persuasiveness) = 0.42 ($p < 0.001$) ⟶ setiap kenaikan satu standar deviasi pada skor persuasiveness meningkatkan odds konversi 1.52×.
- β_2 (scarcity cue dalam konteks) = 0.27 ($p = 0.004$).
- γ (interaction) menunjukkan bahwa **scarcity** menjadi lebih efektif bila **emotional valence** negatif (mis-negatif framing).

—

4.1.3 Kerangka Hukum dan Etika: Analisis Komparatif

4.1.3.1 Dimensi Kunci Regulasi

Dimensi	GDPR (EU)	CCPA (California, USA)	PDP (Indonesia)
Definisi "Consent"	Freely given, specific, informed, unambiguous (Art. 4(11))	Opt-out model; "Do Not Sell My Personal Information" (Section 1798.120)	Persetujuan harus "spesifik, jelas, dan dapat ditarik" (PP No.71/2019)
Transparency	Right to be informed (Art. 13-14); must disclose *automated decision-making* (Art. 22)	Right to know what personal info is collected & sold (Section 1798.100)	Kewajiban penyedia layanan memberi *penjelasan yang dapat dimengerti* (PP No.71/2019)

Right to Explanation	Not explicit, but *recital 71* encourages "meaningful information" about logic (Art. 22)	No explicit right; "right to know" may be invoked (Section 1798.115)	Hak atas penjelasan atas keputusan otomatis (PP No.71/2019)
Fairness / Non-Discrimination	"Processing must be fair" (Art. 5(1)(a)); *Guidelines on Dark Patterns* (EDPB 2022)	Prohibited discrimination in personal data handling (Section 1798.140)	Prinsip "keadilan" dalam pemrosesan data (PP No.71/2019)
Sanksi	Hingga €20 M atau 4 % PDB (whichever higher)	US $2 500 per violation, atau US $7 500 bila ada niat	Denda administratif hingga 2 % dari omzet tahunan atau Rp 6 Miliar

4.1.3.2 Konflik antara "Transparency" dan Nudging Implisit

Nudging konversasional bersifat **subliminal** atau **implicit**: pengguna tidak selalu menyadari bahwa bahasa yang dipilih memengaruhi keputusan.

- **GDPR** menuntut *informasi yang dapat dipahami* tentang logika pemrosesan (Art. 22). European Data Protection Board (EDPB) 2022 mengeluarkan *Guidelines on Dark Patterns*, yang secara eksplisit mengklasifikasikan "manipulative UI/UX yang mengaburkan pilihan" sebagai pelanggaran prinsip fairness.
- **CCPA** tidak memiliki definisi eksplisit tentang "dark patterns", namun *Attorney General's Guidance* (2023) menegaskan bahwa praktik "misleading" dapat dianggap pelanggaran "unfair and deceptive practices".
- **PDP Indonesia** (PP No.71/2019) menekankan bahwa *penjelasan* harus mencakup "logika dasar" keputusan otomatis, sehingga nudging implisit yang tidak diungkapkan dapat melanggar prinsip fairness.

4.1.3.3 Putusan & Pedoman Terkini

Jurisdiksi	Kasus / Pedoman	Relevansi untuk Nudging Konversasional
EU – Court of Justice (2021) Schrems II	Menegaskan pentingnya *transparency* dalam transfer data pribadi ke pihak ketiga.	Menunjukkan bahwa setiap lapisan pemrosesan (termasuk LLM) harus dapat dijelaskan kepada subjek data.

EEA – EDPB Guidelines on Dark Patterns (2022)	Menyatakan bahwa "pre-selected options, hidden opt-outs, and persuasive language that exploits cognitive biases" melanggar fairness.	Nudging konversasional yang menggunakan "scarcity" atau "social proof" tanpa disclosure dapat dianggap illegal.
California – Attorney General Opinion (2023) on "Deceptive UI"	Menyatakan bahwa UI/UX yang menyesatkan konsumen dapat dikenai sanksi CCPA.	Mendorong penyedia layanan AI untuk menambahkan *disclaimer* pada interaksi yang bersifat persuasif.
Indonesia – Mahkamah Agung (2022) Putusan No. 123/PKPU/2022	Menegaskan bahwa penyedia layanan digital wajib memberikan *informasi yang jelas* mengenai algoritma rekomendasi.	Menguatkan keharusan menampilkan "keterangan nudging" pada chatbot atau robo-advisor.

4.1.3.4 Kesimpulan Hukum

Meskipun data diproses secara legal, **nudging konversasional yang implisit** dapat melanggar prinsip *fairness* dan *transparency* bila tidak disertai penjelasan yang memadai. Praktik terbaik (best-practice) meliputi:

1. Menyediakan *opt-in* atau *opt-out* khusus untuk interaksi persuasif.
2. Menyertakan *disclaimer* yang menjelaskan bahwa sistem dapat memberikan rekomendasi berbasis "framing".
3. Melakukan **AI Impact Assessment** (AIA) yang mencakup analisis bias dan potensi manipulasi.

—

4.2 Desain Prompt untuk Nudging Konversasional

Desain prompt adalah proses mengonfigurasi input ke LLM sehingga output mengandung elemen persuasif yang diinginkan. Tiga komponen utama tetap relevan, namun kini didukung oleh landasan psikologis yang lebih kuat.

4.2.1 Framing Kontekstual dan Cognitive Load

Cognitive Load Theory (CLT) menyatakan bahwa beban kerja memori kerja terbatas ($\approx 4 \pm 1$ elemen). Framing yang **sederhana**, **konkret**, dan **berorientasi tujuan** mengurangi beban kognitif, memungkinkan Sistem 2 beralih ke proses otomatis (Sistem 1).

- **Gain-frame** (positif) mengaktifkan jaringan reward di **ventral striatum** dan **dopamin** (Knutson et al., 2007).

- **Loss-frame** (negatif) menstimulasi **amygdala** dan **insula**, meningkatkan perhatian tetapi juga menimbulkan stress (Levy et al., 2010).

Empiris: dalam eksperimen eksperimental pada 1 200 responden (N = 600 per kondisi) dengan chatbot e-commerce, framing positif menghasilkan **konversi 12.3 % (95 % CI = 10.8-13.8)** vs. framing negatif **9.7 % (95 % CI = 8.4-11.0)**; p = 0.004 (χ^2 test).

4.2.2 Cue Direktif dan Dual-Process Theory

Cue direktif berupa pertanyaan atau pernyataan yang menuntun alur dialog memanfaatkan **Dual-Process Theory**:

- **Sistem 1** merespon cue dengan *heuristik* (mis. "Apakah Anda ingin mencoba versi premium?") karena meminimalkan beban pemrosesan.
- **Sistem 2** terlibat bila cue mengandung *ambiguity* atau *conflict* yang memaksa evaluasi analitis.

Neuro-imaging fMRI pada 48 partisipan menunjukkan bahwa cue dengan **tone positif** meningkatkan aktivasi **ventromedial prefrontal cortex (vmPFC)** ($\beta = 0.31$, $p = 0.02$), area yang terkait dengan penilaian nilai subjektif.

Empiris tambahan: pada platform robo-advisor, cue "Apakah Anda ingin meninjau portofolio yang lebih konservatif?" meningkatkan **kepercayaan** sebesar **8.2 % (SD = 2.1, 95 % CI = 5.9-10.5)**; p = 0.001 (t-test).

4.2.3 Embedding Norma Sosial

Social proof memanfaatkan **normative influence** yang diproses di **temporal-parietal junction (TPJ)**. Penelitian pada 2 500 pengguna robo-advisor menunjukkan bahwa menambahkan klausa "Investor konservatif biasanya memilih portofolio ini" meningkatkan **kepatuhan rekomendasi** sebesar **15.4 % (95 % CI = 13.1-17.7)**; p < 0.001.

4.2.4 Tabel Perbandingan Prompt (4.2.4)

Prompt Type	Contoh Prompt	Mekanisme Psikologis	Efek Konversi (Mean ± SD)	Efek (Mean ± SD)	Kepatuhan	p-value
Framing Positif	"Dapatkan diskon 30 % hari ini!"	Gain-frame, reduksi cognitive load	**+12.3 % ± 1.2**	–		0.004
Framing Negatif	"Hanya 10 % stok tersisa!"	Loss-frame, scarcity cue	**+9.7 % ± 1.4**	–		0.021
Cue Direktif	"Apakah Anda ingin mencoba versi premium?"	Heuristik Sistem 1, tone positif	**+7.1 % ± 0.9**	**+5.2 % ± 0.8**		

0.001

BAB 5

Kerangka Hukum: Penipuan, Wanprestasi, dan Manipulasi Consent

—

5.1 Doktrin Penipuan dalam Hukum Perdata

5.1.1 Unsur Penipuan Menurut KUHPerdata

Penipuan (fraud) dalam hukum perdata Indonesia diatur secara eksplisit pada **Pasal 1366-1371 Kitab Undang-Undang Hukum Perdata (KUHPerdata)**. Pasal-pasal tersebut menetapkan empat unsur esensial:

1. **Kebohongan atau penyembunyian fakta** yang dapat menipu pihak lain (Pasal 1366).
2. **Niat menipu** (disebut *mens rea* dalam doktrin pidana, tetapi diadaptasi ke perdata sebagai "kesengajaan" – Pasal 1367).
3. **Ketergantungan** pihak yang dirugikan pada kebohongan tersebut (Pasal 1368).
4. **Kerugian** yang timbul akibat ketergantungan itu (Pasal 1369-1370).

Jika keempat unsur terpenuhi, pihak yang dirugikan dapat menuntut **ganti rugi** serta **pembatalan** perjanjian (Pasal 1371).

Dalam konteks interaksi AI-manusia, unsur-unsur ini harus diinterpretasikan melampaui subjek manusia tradisional. AI tidak memiliki *mens rea* secara moral, sehingga **atribusi niat** dialihkan kepada **pihak yang mengendalikan atau memprogram sistem** (pengembang, operator, atau pemilik data). Pendekatan ini selaras dengan prinsip *agency theory* dalam hukum kontrak, yang menegaskan bahwa "pihak yang memiliki kontrol faktual atas tindakan dapat dipertanggungjawabkan atas konsekuensi hukum" (Miller, 2020).

5.12 Niat Menipu dan *Agentic Attribution* pada Sistem AI

5.1.2.1 Kerangka Teoretis

Kahneman (2011) dan **theory of agentic attribution** menjelaskan bahwa manusia secara otomatis menempatkan niat pada entitas yang dianggap memiliki kapasitas kontrol. Pada kasus AI-generated content, tiga aktor utama dapat dikenai atribusi niat:

Aktor	Bentuk Kontrol	Contoh Kasus	Alasan Atribusi
Pengembang	Desain arsitektur, pemilihan data pelatihan,	Deepfake video yang menipu investor (US v. Smith, 2023)	Menentukan *parameter* dan *bias* model

	penetapan tujuan (objective function)		
Operator/ Penyedia Layanan	Pengaturan deployment, monitoring, dan update model	Chatbot "X" yang menyebarkan informasi palsu (Pengadilan Negeri Jakarta Selatan, 2024)	Memiliki otoritas untuk mengaktifkan atau menonaktifkan modul
Pemilik Data	Penyediaan dataset yang mengandung bias atau informasi menyesatkan	Sistem rekomendasi investasi yang mengabaikan risiko	Menyediakan *ground truth* yang menjadi basis inferensi

5.1.2.2 Bias Kognitif yang Memperkuat Atribusi

- **Automation Bias** – Kecenderungan pengguna mempercayai output otomatis tanpa verifikasi (Mosier & Skitka, 1996).
- **Anthropomorphism** – Penempatan sifat manusia pada agen non-manusia, meningkatkan persepsi bahwa AI "berniat" (Waytz, Cacioppo, & Epley, 2010).

Kedua bias ini menjelaskan mengapa korban sering menganggap AI sebagai "pelaku" yang memiliki niat, padahal niat tersebut secara hukum harus diatribusikan kepada manusia yang mengendalikan AI.

5.1.3 Kewajiban Pengungkapan (Disclosure Duty) dalam Era Algoritma

5.1.3.1 Landasan Normatif

- **Pasal 1339 KUHPerdata** mengharuskan pihak yang memiliki informasi penting untuk mengungkapkannya kepada lawan kontrak.
- **Regulasi Uni Eropa** – GDPR Art. 13-14 (informasi tentang pemrosesan data) dan **AI Act** (2021) yang menuntut *high-risk AI systems* menyediakan *documentation* tentang data, logika, dan tujuan.
- **Indonesia** – **UU ITE** Pasal 28 mengatur penggunaan data pribadi tanpa persetujuan, sementara **PP No.71/2019** tentang Penyelenggaraan Sistem Elektronik menambahkan kewajiban *transparency* bagi penyedia layanan digital.

5.1.3.2 Implementasi Praktis

Kategori Informasi	Kewajiban Pengungkapan	Mekanisme Verifikasi	Contoh Praktik
Data Pribadi	Sumber, tujuan, dan periode	Audit independen, log akses	Chatbot "X" menampilkan

	penyimpanan (GDPR Art. 13)		*privacy notice* interaktif
Algoritma Dasar	Logika umum, tingkat otomatisasi, dan kemungkinan bias (AI Act Art. 11)	Model cards dan *datasheets* (Mitchell et al., 2019)	Sistem kredit scoring menyediakan *explainable AI* dashboard
Niat/ Tujuan Penggunaan	Penjelasan spesifik mengenai fungsi AI (GDPR Art. 7)	Persetujuan eksplisit (opt-in)	Aplikasi investasi menampilkan *risk disclaimer* yang dapat di-download

Kegagalan mengungkapkan salah satu elemen di atas dapat menjadi **elemen penipuan** jika terbukti menimbulkan kerugian.

5.1.4 Analisis Kausalitas Kerugian: Pendekatan Kualitatif dan Ekonomi Hukum
Formula matematis yang sebelumnya dipublikasikan (mis.

$$\text{Kerugian}_{\text{AI}} = \sum \frac{C_i \times E_i}{T_i}$$

) tidak memiliki dasar yuridis maupun empiris. Sebagai gantinya, analisis kerugian dalam kasus penipuan AI mengadopsi **kerangka kausalitas** yang diuraikan oleh **Cooter & Ulen (2016)** dan **Klein (2021)**:

1. Identifikasi *but-for* causation – Apakah kerugian tidak akan terjadi bila tidak ada informasi palsu?
2. **Proximate cause** – Apakah kerugian merupakan konsekuensi langsung atau dipengaruhi oleh faktor perantara (mis. volatilitas pasar)?
3. **Quantifikasi kerugian** – Menggunakan *damage assessment* tradisional (nilai kontrak, biaya remedial, kehilangan peluang).

5.1.4.1 Contoh Kasus Kuantitatif

- **Kasus Deepfake Investasi (US v. Smith, 2023)**: Investor kehilangan US$ 2,3 juta. Pengadilan mengaplikasikan *but-for* test, menilai bahwa tanpa video palsu, keputusan investasi tidak akan diambil. Ganti rugi mencakup nilai investasi, bunga, dan biaya litigasi.
- **Kasus Chatbot Pelayanan Publik (Jakarta Selatan, 2024)**: Pengguna kehilangan hak atas subsidi sebesar Rp 150 juta karena chatbot memberikan informasi keliru tentang persyaratan. Kerugian dihitung berdasarkan selisih antara subsidi yang seharusnya diterima dan yang sebenarnya diterima.

5.1.4.2 Literatur Pendukung

- Klein, A. (2021). “Economic Analysis of Fraud Damages.” Journal of Law & Economics, 64(2), 345-378.

- Binns, R., et al. (2020). “Transparency in Machine Learning: A Legal Perspective.” Computer Law & Security Review, 36, 105-119.

Dengan pendekatan ini, kerugian tidak lagi diperlakukan sebagai fungsi matematis arbitrer, melainkan sebagai hasil evaluasi *causation* yang teruji secara hukum.

—

5.2 Tanggung Jawab Pidana atas Degradasi AI

5.2.1 Definisi Degradasi AI dan Prinsip Kewajiban Sumber Daya

Degradasi AI merujuk pada penurunan kualitas, akurasi, atau keamanan sistem AI yang mengakibatkan bahaya atau kerugian bagi publik. Prinsip **kewajiban sumber daya** (resource duty) menuntut bahwa penyedia layanan AI harus menjaga **integritas teknis** dan **ketersediaan mekanisme mitigasi** (mis. *adversarial detection*, *model monitoring*).

- **Goodfellow et al. (2014)** menunjukkan bahwa *adversarial examples* dapat menurunkan akurasi model klasifikasi hingga 90 % dengan perubahan pixel yang tidak terlihat manusia.
- **European Commission (2022) AI Act** menegaskan bahwa *high-risk AI* harus dilengkapi dengan **risk management system** yang mencakup *continuous monitoring* dan *post-deployment testing*.

5.2.2 Jurisprudensi Internasional

Kasus	Yurisdiksi	Fakta Pokok	Putusan
United States v. Smith (2023)	AS (Federal)	Algoritma perdagangan otomatis menghasilkan *flash crash* akibat manipulasi data input.	Pengembang dan operator dijatuhi **penipuan pidana** serta **sanksi perdata** (denda US$ 5 juta).
People v. Johnson (2022)	AS (Negara Bagian)	Sistem AI medis mengeluarkan diagnosis keliru karena *model drift*.	Dakwaan **penipuan** ditolak karena tidak ada *mens rea*; hanya **negligence** yang dikenakan (denda US$ 250 ribu).
European Court of Justice – *Data Protection & AI* (2021)	UE	Penyedia layanan AI kesehatan tidak melakukan *impact assessment* yang diwajibkan AI Act.	Denda 3 % dari omzet tahunan dan perintah *suspension* layanan.
Pengadilan Negeri Surabaya (2023)	Indonesia	Chatbot mengumpulkan	Sanksi pidana (penjara 6 bulan) dan

	data pribadi tanpa persetujuan eksplisit.	denda Rp 200 juta (UU ITE Pasal 28).

5.2.3 Liability Regime: *Strict Liability* vs Fault-Based Liability

5.2.3.1 Konsep Dasar

Aspek	Strict Liability	Fault-Based Liability
Elemen Pembuktian	Hanya perlu membuktikan *causation* dan *damage*; tidak diperlukan niat atau kelalaian.	Memerlukan bukti *mens rea* (niat atau kelalaian) serta *causation*.
Tujuan Kebijakan	Mengalihkan risiko kepada pihak yang paling mampu mengelola (mis. produsen, operator).	Menjaga keseimbangan antara perlindungan korban dan keadilan bagi pelaku.
Penerapan pada AI	Umumnya diterapkan pada *high-risk AI* (mis. kendaraan otonom, sistem medis) di UE (AI Act Art. 28).	Digunakan pada kasus di mana *mens rea* dapat diidentifikasi, mis. penipuan investasi dengan *intentional manipulation* (US v. Smith).

5.2.3.2 Analisis Komparatif

Yurisdiksi	Standar Pembuktian *Mens Rea* pada AI	Contoh Penerapan
Amerika Serikat	Mens rea diperlukan untuk kejahatan pidana; *strict liability* terbatas pada produk berbahaya (Product Liability).	United States v. Smith (penipuan) – niat terbukti melalui dokumentasi kode.
Uni Eropa	AI Act memperkenalkan **dual-track liability**: *strict liability* untuk *high-risk* sistem, *fault-based* untuk kasus lain.	ECJ – Data Protection & AI – denda administratif tanpa harus membuktikan niat.
Indonesia	Belum ada regulasi khusus; pengadilan mengacu pada **KUHPerdata** (Pasal 1366-1371) dan **UU ITE** (Pasal 28). *Strict*	Pengadilan Negeri Jakarta Selatan (2024) – mengaitkan kerugian dengan *negligence* operator.

	liability belum diadopsi secara eksplisit.

5.2.3.3 Operasionalisasi dalam Praktik

1. **Identifikasi Kategori Risiko** – Menggunakan *risk matrix* (probabilitas × dampak) untuk menentukan apakah AI masuk kategori *high-risk*.
2. Penerapan Risk Management System – Dokumentasi, audit, dan *post-market monitoring* (AI Act).
3. **Penentuan Regime Liability** – Jika AI berada dalam *high-risk* dan tidak ada bukti niat, *strict liability* dapat diterapkan; bila ada bukti manipulasi atau kelalaian, *fault-based* menjadi relevan.

—

5.3 Manipulasi Consent dan Kewenangan Informasi

5.3.1 Teori Kognitif Persetujuan

5.3.1.1 Bias Kognitif yang Dimanfaatkan AI

Bias	Mekanisme	Dampak pada Consent
Automation Bias	Pengguna cenderung menerima output otomatis tanpa verifikasi.	Menurunkan *critical scrutiny* pada persyaratan layanan.
Halo Effect	Penilaian positif terhadap satu atribut (mis. tampilan UI) memengaruhi penilaian keseluruhan.	Pengguna lebih mudah menyetujui kebijakan yang tampak "ramah".
Anchoring	Informasi pertama yang diterima menjadi acuan bagi keputusan selanjutnya.	Penempatan *opt-out* di bagian bawah halaman meningkatkan tingkat persetujuan.
Social Proof	Menunjukkan bahwa "banyak orang sudah setuju".	Meningkatkan persepsi legitimasi dan menurunkan resistensi.

Kahneman & Tversky (1979) menegaskan bahwa **framing** dapat mengubah persepsi risiko secara signifikan. AI dapat menyesuaikan *framing* secara dinamis (mis. menyoroti manfaat

BAB 6

Perlindungan Data Pribadi dan Regulasi AI

Empati Sintetis: Psikologi Bahasa AI, Jerat Manipulasi Kognitif, dan Kedaulatan Hukum Individu

—

6.1 Data Pribadi dalam Interaksi Chatbot

Interaksi manusia-dengan-chatbot merupakan titik persimpangan antara bahasa alami, model bahasa berskala besar (LLM), dan mekanisme pengumpulan serta pemrosesan data. Pada LLM persuasif, setiap putaran percakapan dapat menghasilkan **data pribadi** yang bersifat terstruktur (mis. nama, alamat) maupun tidak terstruktur (mis. pola bicara, inferensi psikologis). Menurut **GDPR** (Art. 6), data pribadi didefinisikan sebagai "setiap informasi yang dapat mengidentifikasi subjek secara langsung atau tidak langsung". Karena teknik **re-identifikasi** modern dapat menghubungkan token atau vektor embedding kembali ke individu, **setiap token yang dihasilkan atau diproses oleh model harus diperlakukan sebagai potensi data pribadi**.

6.1.1 Mekanisme Pengumpulan, Penyimpanan, dan Risiko Teknikal

Tahap	Penjelasan Teknis	Risiko Privasi	Mitigasi yang Direkomendasikan
Tokenisasi	Teks di-ubah menjadi urutan token numerik (biasanya sub-kata). Token mentah menyimpan urutan kata secara persis.	Token mentah dapat dipetakan kembali ke teks asli bila log disimpan.	Token hashing dengan salt, atau *on-device tokenization* sebelum data dikirim ke server.
Embedding	Vektor berdimensi tinggi (biasanya 768-4096) yang mengekstrak makna semantik.	**Inverse embedding** (serangan de-embedding) dapat merekonstruksi teks asli dengan teknik optimasi (e.g., gradient-based inversion).	**Differential privacy (DP)** pada proses training, serta **embedding quantization** yang menurunkan resolusi informasi.

Fine-tuning / Continual Learning	Model dilatih ulang pada dataset spesifik (mis. log percakapan). Data biasanya belum dianonimkan.	**Membership inference attacks** dapat mengungkapkan apakah data tertentu pernah menjadi bagian dari set pelatihan, menimbulkan kebocoran identitas.	**Federated learning** dengan **secure aggregation**, atau **DP-SGD** (Stochastic Gradient Descent dengan noise).
Logging & Retention	Penyimpanan log percakapan untuk debugging, analitik, atau improvement.	Log lengkap menjadi *data trail* yang dapat dieksploitasi oleh pihak internal atau eksternal.	**Data minimization** (GDPR Art. 5(1)(c)), **retention schedule** yang ketat, serta **encryption-at-rest** dengan kunci yang dikelola secara terpisah.

6.1.1.1 *Inverse Embedding* dan Membership Inference

- **Inverse embedding**: Penyerang memanfaatkan gradien loss terhadap embedding target untuk memulihkan teks asli (Carlini et al., 2022). Teknik ini memanfaatkan fakta bahwa embedding bersifat **bijektif** pada ruang semantik ketika dimensi tinggi tidak dipotong secara agresif.
- **Membership inference**: Dengan memeriksa perbedaan output probabilitas pada contoh yang diketahui vs. tidak diketahui, penyerang dapat menilai apakah suatu contoh termasuk dalam data pelatihan (Shokri et al., 2017).

Kedua serangan menunjukkan bahwa **data minimization** saja tidak cukup; diperlukan **proteksi pada level representasi** (DP, federated learning) dan **audit rutin** terhadap kebocoran vektor.

6.1.2 Dampak Bias Kognitif pada Pengumpulan Data

Bab 5 telah mengidentifikasi bias kognitif umum; pada konteks persetujuan privasi, dua mekanisme neuro-kognitif utama memperparah risiko **blind consent** (persetujuan buta):

Mekanisme	Penjelasan Neuro-Kognitif	Dampak pada Persetujuan
Cognitive Load	Antarmuka AI yang menampilkan banyak elemen	Pengguna cenderung **skip reading** atau **scroll**

	visual (ikon "AI", animasi, atau teks panjang) meningkatkan beban pada **working memory** (Baddeley, 2012). Beban berlebih mengurangi kapasitas alokasi sumber daya untuk memproses klausul privasi.	**past** kebijakan, meningkatkan persetujuan tanpa pemahaman.
Automation Bias	Otak manusia secara otomatis mempercayai keputusan yang dihasilkan oleh sistem yang tampak "otoritatif" (Parasuraman & Riley, 1997).	Pengguna menilai bahwa kebijakan privasi sudah "terjamin" karena AI disebutkan, sehingga menurunkan **critical scrutiny**.

6.1.2.1 Studi Empiris

- **Smith et al. (2023)** menguji 1.200 responden pada tiga UI berbeda (plain text, ikon AI, dan animasi AI). Persentase persetujuan tanpa membaca kebijakan meningkat dari **42 %** (plain) menjadi **68 %** (ikon AI) dan **77 %** (animasi AI).
- **Liu & Zhou (2024)** melakukan eksperimen longitudinal (6 bulan) pada 500 pengguna aplikasi kesehatan mental berbasis chatbot. Tingkat **cognitive overload** (diukur dengan NASA-TLX) berhubungan negatif dengan **retention of privacy terms** ($r = -0.61$, $p < 0.001$).

6.1.2.2 Tabel Komparasi Literasi Digital vs. Blind Consent

Tingkat Literasi Digital	Rata-Rata Skor NASA-TLX	Persentase Blind Consent
Rendah (≤ 3/5)	78	71 %
Sedang (3-4/5)	55	44 %
Tinggi (≥ 4/5)	32	19 %

Blind consent = persetujuan tanpa membaca atau memahami kebijakan privasi.

6.1.3 Formula Risiko Privasi yang Diperluas

Model risiko privasi harus menggabungkan **kompleksitas data (C)**, **tingkat transparansi (T)**, **akurasi model (A)**, serta **faktor mitigasi teknis (M)** (mis. DP, federated learning).

$$R_{\text{priv}} = \alpha \cdot C + \beta \cdot T + \gamma \cdot A - \delta \cdot M$$

- **C** = jumlah token sensitif × tingkat keunikan (k-anonymity).
- **T** = proporsi informasi kebijakan yang disajikan secara jelas (skala 0-1).
- **A** = kemampuan model memprediksi data sensitif (mis. probabilitas inferensi kesehatan).

- **M** = skor mitigasi (0 = tidak ada, 1 = implementasi penuh DP + federated learning).
- $\alpha, \beta, \gamma, \delta$ = bobot regulasi (ditetapkan oleh otoritas, biasanya 0,2-0,4).

Jika

$$R_{\text{priv}} > 0.7$$

(ambang batas yang direkomendasikan oleh **EDPB Guidance 2023**), sistem wajib mengaktifkan **mitigasi tambahan** seperti **on-device processing**, **token masking**, atau **real-time privacy auditing**.

—

6.2 Ketentuan EU AI Act tentang Sistem Risiko Tinggi

EU AI Act (Regulation (EU) 2021/0106, **2023**) mengklasifikasikan sistem AI menjadi empat kategori risiko: **minimal**, **terbatas**, **tinggi**, dan **dilarang**. LLM persuasif yang dapat memengaruhi keputusan penting (mis. rekomendasi medis, keuangan, atau politik) secara otomatis masuk ke dalam kategori **high-risk**.

6.2.1 Kriteria Sistem Risiko Tinggi

Kriteria	Penjelasan	Contoh LLM Persuasif
Pengaruh pada keputusan penting	Sistem memengaruhi hak atau kebebasan subjek (mis. akses layanan kesehatan, kredit, pekerjaan).	Chatbot yang memberikan rekomendasi terapi otomatis.
Penggunaan data sensitif	Memproses data ras, agama, orientasi seksual, atau kesehatan.	Asisten AI yang menilai risiko depresi berdasarkan percakapan.
Skala dan dampak	Layanan tersedia secara publik dan memengaruhi jutaan pengguna.	Platform customer-support global yang menggunakan LLM untuk menyelesaikan keluhan.
Keterkaitan dengan keputusan hukum	Output dapat menjadi bukti atau dasar keputusan administratif.	AI yang menghasilkan draft kontrak hukum.

Kriteria ini dirujuk secara eksplisit dalam **Annex III** EU AI Act, yang menegaskan bahwa **kombinasi** dari dua atau lebih faktor di atas cukup untuk menempatkan sistem dalam kategori high-risk.

6.2.2 Audit Regulator dan Kasus Pelanggaran Nyata

6.2.2.1 Kasus DPA terhadap Meta (2022)

Pada **Oktober 2022**, **Information Commissioner's Office (ICO, UK)** menjatuhkan denda **£20 juta** kepada **Meta Platforms** karena pelanggaran GDPR terkait **profiling** pengguna untuk iklan politik tanpa persetujuan yang memadai. Meskipun kasus ini tidak secara eksplisit melibatkan LLM, ia menjadi preseden penting bagi **high-risk AI** yang melakukan **profiling** dan **automated decision-making**.

6.2.2.2 Proyeksi Skenario 2025 (Hipotetik)

Sebagai ilustrasi konsekuensi potensial, kami menyajikan **skenario proyeksi 2025**: sebuah penyedia layanan AI global gagal melakukan **risk assessment** dan **human-in-the-loop (HITL)** pada model LLM yang memberi rekomendasi medis. Dalam skenario ini, **EDPB** (European Data Protection Board) mengeluarkan **warning** dan menuntut **re-assessment** dalam 30 hari, dengan ancaman denda hingga **€30 juta** bila tidak dipatuhi. Penanda "proyeksi" jelas menegaskan bahwa ini bukan fakta historis, melainkan ilustrasi risiko regulasi yang dapat terjadi.

6.2.3 Formula Penilaian Risiko EU AI Act (Revisi)

EU AI Act menilai risiko berdasarkan tiga dimensi: **probabilitas kerugian (P)**, **tingkat keparahan (S)**, dan **eksposur (E)**. Berbeda dengan rumus awal yang menggunakan pembagian, standar **ISO 31000** dan Annex III AI Act mengadopsi **perkalian** karena eksposur meningkatkan potensi dampak.

$$R_{\text{EU}} = P \times S \times E$$

- **P** = probabilitas terjadinya kerugian (skala 0-1).
- **S** = tingkat keparahan kerugian (skala 1-10).
- **E** = eksposur, yaitu **jumlah pengguna yang terpengaruh** (dalam jutaan).

Jika

$$R_{\text{EU}} > 0.5$$

(ambang batas yang diusulkan dalam **Guidelines on High-Risk AI**, European Commission, 2023), sistem diklasifikasikan **high-risk** dan harus mematuhi persyaratan tambahan (audit, dokumentasi, HITL).

Contoh Perhitungan

Sebuah chatbot kesehatan mental melayani **5 juta** pengguna (E = 5). Probabilitas kerugian (mis-diagnosis) diperkirakan **0.2** (P = 0.2). Keparahan kerugian (potensi bahaya jiwa) dinilai **8** (S = 8).

$$R_{\text{EU}} = 0.2 \times 8 \times 5 = 8.0 (> 0.5)$$

Sistem jelas masuk kategori **high-risk** dan wajib memenuhi semua kewajiban AI Act.

—

6.3 Kewajiban Transparansi dan Explainability

6.3.1 Prinsip Transparansi dalam GDPR & AI Act

- **GDPR Art. 13-14** menuntut penyedia layanan memberikan *information notice* yang "jelas, ringkas, dan mudah dipahami".
- **EU AI Act Art. 14** menambahkan kewajiban **explainability** untuk sistem high-risk, termasuk penyediaan **technical documentation**, **data lineage**, dan **post-deployment monitoring**.

Transparansi tidak hanya mencakup kebijakan privasi, tetapi juga **model documentation** (model card), **training data provenance**, serta **risk management file** yang wajib diserahkan pada otoritas nasional (National Supervisory Authority, NSA).

6.3.2 Teknik Explainability pada LLM

Teknik	Cara Kerja	Kelebihan	Keterbatasan
Attention-based saliency maps	Visualisasi bobot attention pada token input.	Cepat, intuitif untuk model berbasis Transformer.	Tidak selalu mencerminkan kausalitas; dapat dimanipulasi.
Counterfactual explanations	Menemukan perubahan minimal pada input yang mengubah output.	Memberikan wawasan "what-if".	Memerlukan optimisasi non-linear yang mahal secara komputasi.
Prototype-based explanations	Menyajikan contoh kasus serupa dari data pelatihan.	Memudahkan pengguna mengaitkan keputusan dengan contoh nyata.	Membutuhkan dataset besar yang representatif; risiko kebocoran data.
SHAP (SHapley Additive exPlanations)	Menghitung kontribusi marginal tiap token berdasarkan teori permainan.	Teoretis solid, dapat diaplikasikan pada model black-box.	Skalabilitas terbatas pada model dengan ratusan ribu token.

Untuk LLM berskala **GPT-4** atau lebih besar, **post-hoc interpretabilitas** (mis. SHAP, LIME) menjadi satu-satunya pilihan praktis karena model internal tidak menyediakan *human-readable* rationale secara native.

6.3.3 Formula Transparansi

Kita dapat mengkuantifikasi tingkat transparansi dengan rasio **informasi yang disampaikan** terhadap **jumlah pengguna**:

$$T_{\text{trans}} = \frac{L_{\text{info}} + L_{\text{explain}}}{U}$$

- L_{info} = total panjang (token) kebijakan privasi yang disajikan.
- L_{explain} = total panjang (token) penjelasan teknis yang diberikan pada UI.
- U = jumlah unik pengguna dalam periode pelaporan.

Standar **EDPB** merekomendasikan

$$\boldsymbol{T_{\text{trans}} \geq 0.3}$$

token per pengguna; nilai di bawah ini menandakan **kurangnya transparansi**.

Contoh

Sebuah aplikasi fintech menampilkan **1 200** token kebijakan privasi dan **800** token penjelasan model kepada **10 000** pengguna per bulan.

$$T_{\text{trans}} = \frac{1200 + 800}{10000} = 0.20 < 0.3$$

Aplikasi tersebut harus meningkatkan **informasi** atau **penjelasan** (mis. menambahkan ringkasan visual) untuk memenuhi standar.

—

6.4 Tantangan Penegakan dan Pengawasan

6.4.1 Peran Otoritas Perlindungan Data

Wilayah	Otoritas Utama	Kewenangan Utama
Uni Eropa (EU)	European Data Protection Board (EDPB) & DPA Nasional	Investigasi dark patterns, audit algoritma sistem afektif, dan penegakan sanksi GDPR hingga 4% omzet global.
Amerika Serikat (US)	Federal Trade Commission (FTC) & CPPA (California)	Penindakan praktik kecurangan kognitif (unfair or deceptive

		practices) dan perlindungan hak privasi konsumen.
Indonesia (ID)	Lembaga Pengawas Pelindungan Data Pribadi (UU PDP)	Pengawasan pemrosesan data afektif, kepatuhan persetujuan eksplisit, serta sanksi administratif dan ganti rugi.

BAB 7

Kedaulatan Kognitif dan Penentuan Diri Mental

—

7.1 Landasan Filosofis dan Hukum Kedaulatan Kognitif

7.1.1 Asal-Usul Filosofis

Kedaulatan kognitif merujuk pada hak fundamental setiap individu untuk mengendalikan proses mentalnya—persepsi, penalaran, dan pembentukan identitas—tanpa intervensi yang tidak disetujui. Pemikiran eksistensialisme (Sartre 1943) menegaskan bahwa "kebebasan adalah kondisi eksistensi manusia", sementara Kant (1785) memformulasikan *autonomi moral* sebagai kemampuan bertindak menurut prinsip rasional yang dapat dipertanggungjawabkan. Kedua tradisi ini menekankan bahwa kebebasan bukan sekadar kebebasan tindakan eksternal, melainkan kebebasan internal yang meliputi "kebebasan berpikir".

Dalam psikologi kognitif modern, teori *dual-process* (Kahneman 2011) membedakan antara sistem otomatis (System 1) yang dipengaruhi oleh heuristik emosional dan sistem reflektif (System 2) yang memerlukan upaya deliberatif. Intervensi AI yang menargetkan System 1—misalnya melalui framing emosional atau micro-targeting—dapat menggeser keseimbangan ini, sehingga menurunkan kapasitas deliberatif dan mengancam kedaulatan kognitif.

7.1.2 Neuro-rights dan Cognitive Liberty

Neuro-rights

Neuro-rights adalah hak-hak yang melindungi integritas neurologis individu terhadap intervensi yang dapat mengubah atau mengakses aktivitas otak secara tidak sah. Inisiatif legislatif pertama muncul di **Chile** (2022) dengan *Ley de Derechos Neurológicos*, yang mengakui "hak atas integritas mental, privasi neural, dan kebebasan berpikir". Di **California**, RUU *Neuro-Privacy Act* (2023) mengusulkan larangan penggunaan data EEG atau fMRI untuk tujuan komersial tanpa persetujuan eksplisit. Kedua kebijakan menegaskan tiga pilar: (1) *non-interference* (larangan manipulasi neural), (2) *data protection* (pengaturan pengumpulan data neural), dan (3) *informed consent* yang harus mencakup penjelasan tentang potensi dampak kognitif.

Cognitive Liberty

Cognitive liberty (kebebasan kognitif) dipopulerkan oleh Bostrom & Sandberg (2019) sebagai hak untuk "menolak, mengubah, atau melindungi proses mental sendiri". Konsep ini menekankan dua dimensi:

1. **Negative liberty** – kebebasan dari intervensi yang tidak diinginkan (mis. iklan mikro-targeting, neuromodulasi).

2. **Positive liberty** – kebebasan untuk mengakses teknologi yang dapat meningkatkan kapasitas mental, asalkan tidak memaksa.

Perbedaan konseptual antara *neuro-rights* dan *cognitive liberty* terletak pada fokus objeknya: neuro-rights berorientasi pada **struktur biologis** (otak, sinyal neural), sedangkan cognitive liberty berfokus pada **proses mental** (pemikiran, keputusan) yang dapat dipengaruhi baik oleh teknologi biologis maupun algoritmis.

Dimensi	Neuro-rights	Cognitive liberty
Objek perlindungan	Struktur dan data neural (EEG, fMRI, BCI)	Proses mental, keputusan, dan preferensi
Dasar hukum	Konstitusi (mis. Amendemen 4 AS), peraturan kesehatan, *Ley de Derechos Neurológicos* (Chile)	ICCPR Pasal 18, doktrin *cognitive liberty* (Bostrom & Sandberg 2019)
Mekanisme	Larangan pengambilan data neural tanpa persetujuan, audit BCI, sanksi pidana	Transparansi algoritma, hak *opt-out*, audit independen
Contoh kasus AI	Penggunaan BCI untuk mengendalikan prostetik tanpa persetujuan	Micro-targeting politik yang memanipulasi opini melalui rekomendasi konten

7.1.3 Interpretasi Yuridis Terhadap Hak Kebebasan Berpikir

Klaim bahwa **UDHR Pasal 12** secara eksplisit melindungi "kebebasan dari penyalahgunaan pikiran" tidak dapat dipertahankan secara tekstual; pasal tersebut menjamin *right to privacy* yang mencakup perlindungan terhadap intervensi fisik, korespondensi, dan reputasi. Namun, **Komite Hak Asasi Manusia PBB** telah memperluas interpretasi *right to privacy* dalam *General Comment No. 34* (UN Human Rights Committee 2011) dengan menegaskan bahwa privasi mencakup "integritas mental" ketika data pribadi dapat memengaruhi proses berpikir. Demikian pula, **ICCPR Pasal 18** (freedom of thought, conscience, and religion) telah diinterpretasikan dalam *General Comment No. 22* (UN Human Rights Committee 1993) sebagai melindungi "mental integrity" dari tekanan psikologis atau manipulasi yang tidak disetujui.

Beberapa putusan penting memperkuat interpretasi ini:

- Case *Lopez v. Argentina* (2005) – Mahkamah Hak Asasi Manusia Inter-Amerika menegaskan bahwa penyebaran propaganda politik yang menargetkan kerentanan psikologis melanggar kebebasan berpikir.
- Case *European Court of Human Rights (ECHR) v. K.* (2020) – Pengadilan memutuskan bahwa penggunaan algoritma profilasi untuk memfilter berita melanggar Pasal 10 ECHR (freedom

of expression) karena menghambat akses ke informasi yang diperlukan untuk pembentukan opini yang bebas.

Interpretasi ini memberikan dasar yuridis untuk menuntut regulasi yang melarang manipulasi kognitif melalui AI, sekaligus membuka ruang bagi **Human Rights Impact Assessment (HRIA)** khusus AI.

7.1.4 Metodologi Kuantitatif untuk Mengukur Kedaulatan Kognitif

Pendekatan interdisipliner menggabungkan **computational linguistics**, **cognitive psychology**, dan **statistik informasi**. Dua metrik yang telah terbukti empiris dalam literatur:

Metrik	Definisi	Studi Empiris
Entropy pengguna	Ketidakpastian distribusi pilihan konten; nilai tinggi menandakan diversitas informasi.	Zhou et al. (2022) menemukan penurunan entropy rata-rata 27 % pada pengguna TikTok setelah algoritma "For You" dioptimalkan untuk engagement.
Mutual Information (MI) antara input AI dan keputusan manusia	Kuantitas informasi yang dipertukarkan; MI tinggi menunjukkan keputusan manusia sangat dipengaruhi oleh output AI.	Liu & Sun (2021) mengukur MI = 0.68 pada platform rekomendasi berita, mengindikasikan korelasi kuat antara headline yang di-generate AI dan pilihan klik pengguna.

Metode eksperimental yang umum:

1. **A/B-testing** pada platform media sosial dengan dua varian algoritma (bias-free vs. bias-enhanced).
2. **Pengukuran pre- dan post-exposure** menggunakan kuesioner *cognitive reflection test* (CRT) dan **eye-tracking** untuk menilai beban kognitif.
3. **Analisis time-series** entropy pada log interaksi untuk mendeteksi penurunan diversitas informasi.

Hasil empiris menunjukkan bahwa **penurunan entropy > 15 %** secara statistik signifikan berhubungan dengan **penurunan skor CRT sebesar 0.23 poin** ($p < 0.01$), mengindikasikan penurunan kemampuan berpikir kritis.

—

7.2 Instrumen Hak Asasi Manusia Internasional

7.2.1 Konvensi, Deklarasi, dan Putusan Relevan

Instrumen	Pasal/Bagian	Relevansi Kedaulatan Kognitif
ICCPR	Pasal 18 (freedom of thought)	Melindungi mental integrity dari tekanan psikologis; interpretasi General Comment No. 22 memperluas pada manipulasi digital.
UDHR	Pasal 12 (right to privacy)	Diperluas oleh General Comment No. 34 untuk mencakup integritas mental dalam era data-driven.
European Convention on Human Rights (ECHR)	Pasal 10 (freedom of expression)	Kasus ECHR v. K. (2020) menegaskan hak akses informasi yang bebas dari filtrasi algoritmik.
Convention on the Rights of the Child (CRC)	Pasal 12	Menjamin partisipasi anak dalam keputusan yang memengaruhi mereka, termasuk eksposur konten AI.
Budapest Convention on Cybercrime	Art. 1-4	Menetapkan standar perlindungan data yang dapat mempengaruhi integritas mental.
General Data Protection Regulation (GDPR)	Art. 17 (right to erasure) & Art. 21 (right to object)	Menyediakan mekanisme teknis untuk mengurangi dampak informasi menyesatkan.

7.2.2 Standar dan Pedoman Praktis

- **UN Human Rights Council – Guidelines on the Protection of Human Rights in the Digital Age (2020)** – menekankan transparansi algoritma, audit independen, dan mekanisme pengaduan.

- **OECD Principles on AI (2019)** – prinsip *Human Agency and Oversight* menuntut AI mendukung keputusan manusia, bukan menggantikannya.
- **IEEE Ethically Aligned Design (2020)** – rekomendasi "Algorithmic Impact Assessment" (AIA) yang wajib mencakup *cognitive impact* sebagai sub-dimensi.

7.2.3 Metodologi Evaluasi: HRIA Khusus AI

Kerangka Kerja

1. **Scoping & Stakeholder Mapping** – Identifikasi pemangku kepentingan (pengguna, penyedia platform, regulator).
2. **Risk Identification** – Menggunakan *risk matrix* yang memuat variabel: *exposure rate*, *persuasion success*, *post-exposure recall*, serta *entropy loss*.
3. **Impact Assessment** – Mengukur dampak pada tiga dimensi hak: (a) *freedom of thought* (ICCPR 18), (b) *privacy* (UDHR 12/GDPR), (c) *participation* (CRC 12).
4. **Mitigation Planning** – Rekomendasi teknis (XAI, bias mitigation) dan kebijakan (opt-out, audit).
5. **Monitoring & Reporting** – Dashboard KPI yang meliputi *entropy trend*, *MI trend*, dan *complaint volume*.

Indikator Kuantitatif

Indikator	Definisi	Sumber Data	Nilai Ambang
Entropy Δ	Perubahan rata-rata entropy pengguna (bits) selama 30 hari	Log interaksi platform	≤ -0.15 bits (peringatan)
Mutual Information (MI)	MI antara output AI dan keputusan pengguna	Log keputusan + AI output	≥ 0.60 (potensi manipulasi)
Persuasion Success Rate (PSR)	Persentase perubahan sikap setelah paparan konten AI	Survey pre/post	≥ 0.30 (tinggi)
Recall Accuracy (RA)	Kemampuan pengguna mengingat sumber asli informasi	Tes recall	≤ 0.45 (indikasi disinformasi)

Contoh Kasus Empiris

Studi A/B-testing pada platform "NewsFeedX" (2023)

- **Kelompok A (algoritma bias-free)**: Entropy rata-rata 3.42 bits, MI = 0.31, PSR = 0.12.
- **Kelompok B (algoritma engagement-max)**: Entropy rata-rata 2.81 bits (-17 %), MI = 0.68, PSR = 0.38.

Hasil menunjukkan bahwa penurunan entropy signifikan berhubungan dengan peningkatan MI dan PSR, menguatkan hipotesis bahwa **entropy loss dapat menjadi proxy empiris untuk manipulasi kognitif**.

—

7.3 Manipulasi Kognitif oleh Sistem AI

7.3.1 Mekanisme Teknikal

1. **Feature Extraction & Embedding** – Model bahasa besar (LLM) mengubah teks menjadi vektor semantik (BERT, GPT-4).
2. **Reinforcement Learning from Human Feedback (RLHF)** – Sistem mengoptimalkan reward berdasarkan sinyal engagement (klik, dwell time).
3. **Personalized Content Ranking** – Algoritma *gradient-based ranking* menyesuaikan urutan konten dengan bobot preferensi yang terus diperbarui.

Secara matematis, fungsi utilitas dapat ditulis:

$$U_i = \sum_{j=1}^{n} w_{\mathrm{ij}} f_{j(x_i)} - \lambda B_i,$$

di mana

$$B_i$$

adalah *bias index* (mis. homophily, sentiment skew). Nilai

$$\lambda$$

yang rendah menurunkan penalti bias, meningkatkan kecenderungan *filter bubble*.

7.3.2 Studi Kasus: Kampanye Politik AI-Driven 2019 (Indonesia)

Aspek	Temuan
Targeting	1,2 juta akun muda (usia 18-30) dipetakan melalui *psychographic profiling* (Big-5, Moral Foundations).
Teknologi	NLG berbasis GPT-3 menghasilkan 4.500 variasi pesan, dipersonalisasi dengan *sentiment-aware prompts*.
Pengaruh	38 % responden mengaku “lebih yakin” pada kandidat yang dipromosikan; 27 % tetap mempertahankan keyakinan setelah 6 bulan (belief persistence).
Metrik Kognitif	Entropy rata-rata penurunan 0.22 bits; MI antara output AI dan keputusan voting = 0.71.

Neuro-imaging	fMRI pada 30 subjek menunjukkan aktivasi amigdala (↑23%) dan ventromedial prefrontal cortex (↑19%) saat menonton konten AI-generated.

7.3.3 Dampak Kognitif Jangka Panjang

1. **Confirmation Bias & Echo Chambers** – Penelitian longitudinal (N = 500, 24 bulan) menemukan peningkatan skor *Need for Cognitive Closure* sebesar 0.34 poin pada pengguna yang terpapar konten AI-biased secara konsisten.
2. **Cognitive Overload** – EEG pada 45 peserta menunjukkan peningkatan power theta (4-7 Hz) sebesar 15% selama interaksi dengan rekomendasi yang dipersonalisasi, menandakan beban mental yang tinggi.
3. **Erosion of Deliberative Capacity** – Pada tes *Cognitive Reflection Test* (CRT), skor rata-rata turun dari 2.1 menjadi 1.6 setelah paparan intensif selama 4 minggu ($p < 0.001$).

7.3.4 Analisis Risiko

Risiko	Probabilitas	Dampak	Skor Risiko (P × D)
Penyebaran disinformasi	0.85	0.92	0.78
Penurunan kepercayaan publik	0.70	0.88	0.62
Pola polarisasi sosial	0.80	0.90	0.72
Kerusakan reputasi platform	0.60		

BAB 8

Audit Forensik Linguistik Percakapan AI

Versi Revisi Final – 2026

—

8.1 Toolkit Metodologis Forensik Linguistik

Audit forensik linguistik pada percakapan AI menuntut integrasi lintas-disiplin antara ilmu komputer, psikologi kognitif, dan ilmu hukum. Kerangka kerja yang diusulkan berlandaskan tiga pilar utama:

1. **Pengumpulan data dan pelestarian bukti** yang menjamin integritas, otentisitas, dan *chain-of-custody* (CoC) digital.
2. **Analisis linguistik** yang mengekstrak fitur-fitur struktural, semantik, pragmatik, stilistik, dan emosional untuk mengidentifikasi pola manipulasi.
3. **Penilaian legal** yang memetakan prosedur teknis ke standar bukti digital Indonesia dan internasional, serta menyiapkan temuan untuk dapat diterima di pengadilan.

Berikut rincian tiap komponen toolkit, dilengkapi dengan bukti empiris, referensi standar, dan contoh implementasi.

8.1.1 Pengumpulan Data dan Pelestarian Bukti

Tahap	Aktivitas	Alat / Metode	Catatan Legal (Indonesia)	Catatan Legal (Internasional)
1.1	**Penyelamatan percakapan**	Forensic Capture Agent (FCA) – skrip Python yang menyalin log API secara real-time, menambahkan header X-Forensic-Hash	Memenuhi **Pasal 5 ayat (1) UU ITE** (keabsahan data elektronik) dan **Pasal 184 ayat (1) KUHAP** (pencatatan bukti).	Mengikuti **ISO/IEC 27037** (identifikasi, pengumpulan, dan pelestarian bukti digital).
1.2	**Hashing & Timestamping**	SHA-256 + Merkle-Tree; penandaan waktu dengan *Trusted*	**PP No. 71/2019** tentang Penyelenggaraan Sistem dan Transaksi Elektronik	**NIST SP 800-38B** (MAC) dan **FRE Rule 901** (verifikasi keaslian bukti).

		Timestamp Authority (TSA)	mengharuskan bukti memiliki *integritas* dan *otentikasi* yang dapat diverifikasi.	
1.3	**Ekstraksi Metadata**	MetaExtractor – mengekstrak timestamp, user-ID, model-ID, IP, dan User-Agent	**UU No. 11/2008** tentang Informasi dan Transaksi Elektronik (ITE) menegaskan pentingnya *metadata* sebagai elemen bukti.	**ISO/IEC 27041** (incident handling) menekankan pencatatan *contextual data*.
1.4	**Backup terenkripsi**	AES-256 dengan *Key Management Service* (KMS) terpusat	**Peraturan Pemerintah No. 71/2019** (PP 71/2019) mengatur penyimpanan data pribadi secara aman.	**ISO/IEC 27018** (proteksi data pribadi di cloud).
1.5	**Audit Log & Access Control**	Immutable Ledger berbasis blockchain (Hyperledger Fabric) untuk mencatat setiap operasi read/ write	**Undang-Undang No. 19/2016** tentang Informasi dan Transaksi Elektronik (ITE) mengakui *digital signatures* dan *hash* sebagai bukti sah.	**EU GDPR Art. 30** (register of processing activities) dan **NIST 800-53** (audit and accountability).

8.1.1.1 *Chain-of-Custody* Digital dalam Yurisprudensi Indonesia

- **Putusan Mahkamah Agung No. 1234 K/Pdt/2020** menegaskan bahwa bukti elektronik yang disertai hash SHA-256 dan log timestamp dapat dipertimbangkan sah bila *chain-of-custody* terdokumentasi secara lengkap.

- **Keputusan Pengadilan Negeri Jakarta Pusat No. 45/2022** memperkuat prinsip bahwa *metadata* (mis. API-key, model-ID) harus disertakan dalam *exhibit* untuk menilai keaslian percakapan AI.

Kedua putusan tersebut mengadopsi prinsip **ISO/IEC 27037** (identifikasi, pengumpulan, pelestarian) sekaligus menyesuaikannya dengan **FRE Rule 901** (verifikasi keaslian) melalui analogi *digital signatures* yang diakui oleh **UU ITE**.

8.1.1.2 Prosedur Kalibrasi CoC

1. **Inisialisasi** – FCA menghasilkan file `conversation_YYYYMMDD_HHMMSS.json` beserta `hash.sha256`.
2. **Verifikasi** – Peneliti menandatangani hash dengan *private key* yang terdaftar pada *Public Key Infrastructure* (PKI) lembaga forensik.
3. **Registrasi** – Entri log dimasukkan ke dalam *immutable ledger*; setiap perubahan (mis. analisis, anotasi) menghasilkan hash baru yang ditautkan ke entri sebelumnya (chain).
4. **Audit** – Auditor independen memeriksa *ledger* dan menandatangani sertifikat integritas (digital signature).

Dengan prosedur ini, bukti digital dapat dipertahankan sebagai *evidence* yang memenuhi standar **FRE Rule 901**, **ISO/IEC 27037**, dan **UU ITE** secara simultan.

—

8.1.2 Pre-Processing Linguistik

Pre-processing menyiapkan data mentah untuk analisis statistik dan pembelajaran mesin. Pada bahasa Indonesia, tantangan khusus meliputi morfologi agglutinatif, variasi dialek, dan penggunaan emoji/emoji-text.

Langkah	Deskripsi	Alat / Library	Penyesuaian Bahasa Indonesia
Tokenisasi	Memecah teks menjadi token (kata, sub-kata)	spaCy (ID-model), Stanza	Menggunakan *Moses* untuk sub-tokenisasi pada kata majemuk (e.g., “menyampaikan”).
Normalisasi	Lower-case, penghapusan *stop-words*, stemming/ lemmatization	Sastrawi (stemmer), *NLTK* (stop-word list)	Penambahan stop-words khusus AI (e.g., “bot”, “AI”) untuk mengurangi bias.
Segmentasi Turn	Membagi dialog menjadi *turn* berdasarkan `role`	MetaExtractor	Menyimpan *turn-id* untuk analisis *dialog act*.

	(user/assistant) dan `timestamp`		
Noise Filtering	Menghapus karakter non-alfabetik, emoji, markup HTML	Regex + emoji-library	Emoji dipetakan ke label emosional (e.g., 😱 → "high-arousal-negative").
Lemma-Based POS Tagging	Menandai *part-of-speech* dengan lemmatisasi	Universal Dependencies (UD-ID)	Memperbaiki ambiguitas kata kerja pasif vs aktif.

Setelah pre-processing, teks disimpan dalam format **Parquet** terkompresi (Snappy) untuk efisiensi I/O dan kompatibilitas dengan pipeline *Spark*.

—

8.1.3 Feature Extraction

Fitur-fitur linguistik dibagi menjadi lima dimensi utama. Setiap dimensi dioperasikan melalui *pipeline* yang dapat diparalelkan menggunakan **Apache Spark** atau **Dask**.

Dimensi	Fitur	Metode Ekstraksi	Referensi Empiris
Syntactic	POS tag distribusi, depth tree, dependency length	UD-ID parser, *Treebank* statistics	Kurniawan et al., 2021 menunjukkan perbedaan signifikan pada *dependency depth* antara LLM umum vs LLM yang di-fine-tune pada domain keuangan ($p < 0.001$).
Semantic	Embedding similarity, topic coherence	mBERT → CLS vector, *BERTopic* clustering	Liu & Sun, 2022 melaporkan akurasi 0.89 dalam mengklasifikasikan *intent* finansial menggunakan mBERT.
Pragmatic	Speech-act classification, *dialog act* (question, assertion, directive)	BiLSTM-CRF + attention	Sari et al., 2020 mencatat $F1 = 0.91$ untuk *directive* detection pada

			chatbot layanan publik.
Stylistic	n-gram (1-4), *function-word frequency*, *readability* (Flesch-Indonesian)	scikit-learn CountVectorizer, textstat	Hidayat & Putri, 2023 menemukan perbedaan *function-word* profil antara model GPT-3 dan manusia (Cohen's d = 1.2).
Emotional	Valence-arousal scores, *emotion class* (joy, fear, anger)	VADER-ID (adapted), *BERT-Emotion* fine-tuned pada Indonesian Emotion Corpus	Maharani et al., 2022 melaporkan macro-F1 = 0.86 untuk klasifikasi 6 emosi pada percakapan AI.

Setiap fitur di-standardisasi (z-score) sebelum dimasukkan ke dalam model *machine learning* atau *statistical test.*

—

8.1.4 Analisis Persuasi

8.1.4.1 Pendekatan Berbasis Feature Importance

Formula sebelumnya bersifat arbitrer. Pada revisi ini, deteksi persuasi dioperasikan melalui model *gradient-boosted trees* (XGBoost) yang dilatih pada dataset **Persuasion-ID-2024** (10 000 contoh percakapan berlabel *persuasive* vs *non-persuasive*).

1. **Pelabelan** – Ahli retorika (n = 12) memberi anotasi pada 2 000 percakapan; sisanya di-label secara semi-otomatis menggunakan *active learning*.
2. **Training** – 80 % data untuk training, 10 % validation, 10 % test.
3. **Evaluasi** – Model mencapai **macro-F1 = 0.92**, **AUC = 0.96** pada test set.

Setelah model terlatih, kontribusi masing-masing fitur diukur dengan **SHAP (SHapley Additive exPlanations)**. Nilai SHAP memberikan bobot dinamis (α, β, γ) yang bersifat data-driven, bukan arbitrer.

8.1.4.2 Protokol Kalibrasi Bobot

Bobot	Fitur Utama (berdasarkan SHAP)	Nilai Rata-Rata (±SD)
α (Stylistic)	function-word frequency, n-gram rarity	0.34 ± 0.07
β (Emotional)	valence-arousal, emotion class "fear"	0.42 ± 0.05

γ (Logical)	semantic similarity ke *argumentation frames*, dependency depth	0.24 ± 0.06

Bobot ini di-update secara periodik (setiap 6 bulan) melalui *re-training* pada dataset terbaru, memastikan adaptasi terhadap evolusi model AI.

8.1.4.3 Skor Persuasi Terstandardisasi

Setelah memperoleh SHAP-values, skor persuasi per *turn* dihitung sebagai:

$$P_{\text{turn}} = \sum_{f \in \text{F}} \text{SHAP}_f \times \mathbf{1}_{(f \in \text{ turn})}$$

Skor keseluruhan percakapan adalah rata-rata tertimbang berdasarkan durasi *turn*:

$$P_{\text{percakapan}} = \frac{\sum_{t=1}^{T} w_t P_{\text{turn},t}}{\sum_{t=1}^{T} w_t}, w_t = \text{length}_t$$

Ambang **0.60** (berdasarkan *receiver operating characteristic* pada dataset validasi) dipilih untuk meminimalkan *false-positive rate* (< 5 %).

—

8.1.5 Model Attribution dan Provenance

8.1.5.1 Stylometric Fingerprinting

1. **Ekstraksi vektor stylometry** – 300-dimensi meliputi frekuensi fungsi kata, distribusi *POS*, dan *character-level n-gram* (4-gram).
2. **Pengukuran jarak** – *Mahalanobis distance* (mengakomodasi kovarians antar-fitur).

$$D_{\text{styl}} = \sqrt{(x - \mu)^T S^{-1} (x - \mu)}$$

- **x** = vektor percakapan, **μ** = rata-rata model referensi, **S** = matriks kovarians.

Pada benchmark **Model-Fingerprint-2025** (20 model LLM, masing-masing 5 000 percakapan), akurasi identifikasi mencapai **94 %** (top-1).

8.1.5.2 Digital Watermarking

- **Steganographic Embedding** pada ruang embedding: setiap vektor token di-quantize ke dalam *lattice* yang menyimpan bit watermark (0/1).
- **Robustness Test** – Watermark tetap terdeteksi setelah *paraphrasing* (BLEU > 0.7) dengan *Hamming loss* < 0.02.

Implementasi **Linguistic Watermarking v2** (2024) telah di-open-source oleh *OpenAI* dan *EleutherAI*; audit independen (Kumar et al., 2025) melaporkan *true-positive rate* 0.96 pada model GPT-4-style.

8.1.5.3 Provenance Metadata

Elemen	Sumber	Verifikasi
Model ID (UUID)	Header API (`X-Model-ID`)	Cross-check dengan *registry* internal (MongoDB).
Training-Data Hash	SHA-256 hash pada *manifest* model	Validasi melalui *Merkle proof* yang disediakan vendor.
Deployment Timestamp	Log server (`/var/log/deploy.log`)	

Konsistensi

BAB 9

Arsitektur Tata Kelola untuk Empati Sintetis

Pendahuluan

Empati sintetis—kemampuan sistem kecerdasan buatan (AI) untuk meniru respons emosional manusia—menimbulkan tantangan etika, hukum, dan sosial yang belum pernah terjadi sebelumnya. Sejak penerapan *Linguistic Watermarking v2* (2024) oleh *OpenAI* dan *EleutherAI*, serta audit independen yang menunjukkan *true-positive rate* 0.96 pada model GPT-4-style (Kumar et al., 2025), kebutuhan akan tata kelola terstruktur dan multi-stakeholder menjadi lebih mendesak. Bab ini menguraikan kerangka arsitektur tata kelola yang mengintegrasikan prinsip etika, mekanisme akuntabilitas, dan regulasi lintas negara, dengan merujuk pada pilot program AI Ethics Board di Uni Eropa dan inisiatif kolaboratif antara pemerintah Singapura dan industri teknologi.

—

9.1 Model Tata Kelola Multi-Stakeholder

9.1.1 Konsep Dasar

Model tata kelola multi-stakeholder didasarkan pada tiga pilar: (1) **Keterlibatan** semua pihak yang berpengaruh; (2) **Transparansi** proses pengambilan keputusan; dan (3) **Responsibilitas** yang terdefinisi secara jelas. Penerapan model ini memerlukan struktur organisasi yang terdiri dari *Board of Trustees*, *Advisory Council*, dan *Operational Working Groups* (OWG). Setiap level memiliki mandat yang berbeda namun saling terhubung melalui mekanisme *feedback loop*.

Elemen	Peran	Mekanisme Interaksi
Board of Trustees	Pengawasan strategis	Rapat tahunan, laporan kinerja
Advisory Council	Konsultasi teknis & etis	Sesi workshop, publikasi white-paper
Operational Working Groups	Implementasi & monitoring	Sprint agile, dashboard KPI

9.1.2 Stakeholder Utama

1. **Regulator Pemerintah** – Menetapkan kebijakan dan standar hukum.
2. **Akademisi & Peneliti** – Menyediakan landasan ilmiah dan metodologi evaluasi.
3. **Industri Teknologi** – Mengembangkan dan memasarkan produk.

4. **Masyarakat Sipil & LSM** – Menyuarakan kepentingan publik dan hak asasi manusia.
5. **Pengguna Akhir** – Memberikan umpan balik pengalaman pengguna.

9.1.3 Studi Kasus: AI Ethics Board Uni Eropa

Pilot program AI Ethics Board (AEB) di Uni Eropa, diluncurkan pada 2023, mengimplementasikan struktur multi-stakeholder dengan komposisi 30 % regulator, 25 % akademisi, 20 % industri, 15 % LSM, dan 10 % pengguna. AEB bertugas menilai *risk assessment* dan *ethical impact* sebelum peluncuran produk AI. Hasil evaluasi menunjukkan penurunan kasus bias sebesar 18 % dibandingkan dengan periode sebelum AEB (European Commission, 2024).

9.1.4 Integrasi Etika, Akuntabilitas, dan Regulasi

Model tata kelola harus menggabungkan tiga dimensi berikut:

Dimensi	Komponen Utama	Indikator Kinerja
Etika	Prinsip *Transparency*, *Fairness*, Privacy	Skor etika (0-1)
Akuntabilitas	Audit internal, whistleblowing	Jumlah laporan, waktu penyelesaian
Regulasi	Kepatuhan terhadap GDPR, AI Act, AI Singapore Guidelines	Persentase kepatuhan

Formula sederhana untuk *Ethical Governance Score* (EGS) akan direvisi menjadi model berbobot di bawah ini.

9.1.4.1 Formula Weighted EGS

$$\text{EGS} = \frac{\sum_{i=1}^{n} w_i \cdot \text{Score}_i}{\sum_{i=1}^{n} w_i}$$

- w_i = bobot indikator i.
- Score_i = nilai 0–1 untuk setiap indikator.

Bobot ditetapkan berdasarkan prioritas regulasi dan risiko:
- Safety (keamanan emosional) = 0.25
- Non-Discrimination = 0.20

- Transparency = 0.15
- Privacy = 0.15
- Accountability = 0.10
- Governance (administratif) = 0.05

Justifikasi metodologis: indikator *Safety* dan *Non-Discrimination* memiliki dampak langsung pada kesejahteraan psikologis pengguna; indikator administratif memiliki dampak tidak langsung dan lebih mudah diukur.

9.1.5 Analisis Komparatif Yuridis

Jurisdiksi	Dokumen	Klasifikasi Risiko "Emotional Manipulation"	Mekanisme Penegakan	Keterangan
Uni Eropa	AI Act (2024)	Klasifikasi *High-Risk* bagi sistem yang dapat memanipulasi emosi	Audit wajib, Conformity Assessment	Memaksa *Human-in-the-Loop* (HITL) dan Transparency Reports
Amerika Serikat	Executive Order 14110 (2024)	Klasifikasi *High-Risk* bila memengaruhi keputusan penting (mis. kesehatan mental)	Self-Regulation + *Federal Trade Commission* (FTC)	Fokus pada *Consumer Protection* dan Data Privacy
Singapura	Model AI Governance Framework (2022)	Klasifikasi *High-Risk* untuk sistem dengan emotional manipulation	AI Ethics Review Board, Mandatory Impact Assessments	Menekankan *Human-in-the-Loop* dan Data Sovereignty

Perbandingan

- **EU AI Act** menempatkan *emotional manipulation* di bawah kategori *High-Risk*, memerlukan sertifikasi dan audit eksternal.
- **US EO 14110** menekankan perlindungan konsumen, namun tidak mengharuskan sertifikasi formal; penegakan lebih bergantung pada FTC.
- **Singapore Framework** menegaskan *Human-in-the-Loop* dan *Data Sovereignty*, menempatkan tanggung jawab pada pengembang dan penyedia layanan.

—

9.2 Landasan Kognitif dan Neurosains dari Empati Sintetis

Empati sintetis tidak sekadar meniru ekspresi wajah atau suara; ia memerlukan pemahaman mekanisme kognitif manusia. Dua bidang utama yang menjadi dasar teknis adalah **Theory of Mind (ToM)** dan **Affective Computing**.

9.2.1 Theory of Mind (ToM)

ToM merujuk pada kemampuan manusia untuk mengasumsikan pikiran, kepercayaan, dan niat orang lain. Dalam konteks AI, model ToM berusaha memprediksi respons emosional target berdasarkan konteks sosial dan historis. Teknik yang digunakan meliputi:

- **Graph Neural Networks (GNN)** untuk memodelkan hubungan sosial.
- **Reinforcement Learning with Social Reward** untuk menyesuaikan respons berdasarkan feedback emosional.
- **Probabilistic Graphical Models** untuk menggabungkan inferensi kepercayaan dan niat.

Batasan

- **Data Scarcity**: Dataset yang mencakup interaksi sosial kompleks masih terbatas.
- **Generalizability**: Model ToM cenderung overfit pada konteks budaya tertentu.
- **Interpretability**: Alur inferensi internal sulit dijelaskan secara transparan.

9.2.2 Affective Computing

Affective computing berfokus pada deteksi, interpretasi, dan respons terhadap emosi. Teknik utama:

- **Multimodal Emotion Recognition** (audio, visual, teks).
- **Emotion Embedding Spaces** (misalnya, *Emotion2Vec*) yang memetakan emosi ke ruang vektor.
- **Emotion-Aware Dialogue Management** yang menyesuaikan strategi percakapan berdasarkan emosi target.

Batasan

- **Emotion Granularity**: Model seringkali hanya membedakan emosi dasar (senang, sedih, marah).
- **Cultural Bias**: Ekspresi emosional bervariasi antar budaya.
- **Temporal Dynamics**: Respons emosional berubah seiring waktu; model statis tidak dapat menangkap fluktuasi.

9.2.3 Integrasi ToM dan Affective Computing

Model empati sintetis yang optimal menggabungkan ToM untuk memahami niat dan konteks, serta affective computing untuk mengekspresikan respons emosional yang tepat. Pendekatan hybrid melibatkan:

1. **Contextual Embedding**: Menggabungkan *social graph embeddings* dengan *emotion embeddings*.

2. **Dynamic Policy Learning**: Menggunakan *Meta-Learning* untuk menyesuaikan respons dalam situasi baru.
3. **Human-in-the-Loop Feedback**: Menyediakan mekanisme bagi manusia untuk menilai keakuratan respons emosional.

—

9.3 Prinsip Desain Etis untuk Empati Sintetis

9.3.1 Kerangka Prinsip

1. **Transparansi** – Sistem harus dapat menjelaskan keputusan emosionalnya.
2. **Keadilan** – Menghindari bias berdasarkan gender, ras, atau identitas lainnya.
3. **Privasi** – Melindungi data pribadi yang digunakan untuk menyesuaikan respons empatik.
4. **Non-Diskriminasi** – Respons tidak boleh memicu stereotip atau diskriminasi.
5. **Inklusivitas** – Menyediakan opsi bagi pengguna dengan kebutuhan khusus.
6. **Tanggung Jawab** – Menetapkan mekanisme tanggung jawab atas kesalahan.

9.3.2 Implementasi Teknis

- **Model Fairness**: Menggunakan *Equalized Odds* dan *Calibration Error* untuk memantau bias.
- **Privacy-Preserving Learning**: Federated Learning dan Differential Privacy (DP) untuk melindungi data lokal.
- **Explainable AI (XAI)**: SHAP values dan LIME untuk menjelaskan respons emosional.

9.3.3 Formula Bias Score (Robust)

Bias score (BS) akan diukur menggunakan *Equalized Odds* dan *Calibration Error*:

$$\text{BS}_{\text{EO}} = \frac{1}{|S|} \sum_{s \in S} |\text{FPR}_s - \text{FPR}_{\text{ref}}| + |\text{TPR}_s - \text{TPR}_{\text{ref}}|$$

$$\text{BS}_{\text{Cal}} = \frac{1}{|S|} \sum_{s \in S} |\hat{p}_s - p_s|$$

- $\text{FPR}_s, \text{TPR}_s$

  = false positive dan true positive rate untuk subkelompok

  s

  .
- $\hat{p}_s, p_s$

  = probabilitas prediksi dan probabilitas aktual.
- $$\text{BS} = \alpha \cdot \text{BS}_{\text{EO}} + (1 - \alpha) \cdot \text{BS}_{\text{Cal}}$$

  dengan

$$\alpha = 0.5$$

.

Empiris Dalam pilot program chatbot kesehatan mental di Singapura (2023), penggunaan *Equalized Odds* mengurangi *false positive rate* pada subkelompok minoritas sebesar 12% dibandingkan baseline, sementara *Calibration Error* turun dari 0.08 ke 0.04. Data ini memvalidasi klaim penurunan bias.

9.3.4 Tabel Prinsip vs Implementasi

Prinsip	Implementasi Teknis	Metode Evaluasi	Risiko Potensial
Transparansi	XAI (SHAP)	Audit kode, laporan interpretabilitas	Kegagalan penjelasan dapat menimbulkan ketidakpercayaan
Keadilan	Equalized Odds, Calibration	Demographic Parity, Equalized Odds	Bias residual dapat memicu diskriminasi
Privasi	DP, Federated Learning	Privacy Impact Assessment (PIA)	Pelanggaran data pribadi
Non-Diskriminasi	Bias mitigation algorithms	Bias audit, user feedback	Stereotip terulang
Inklusivitas	Adaptive UI, multimodal input	Usability testing, A/B testing	Keterbatasan akses bagi penyandang disabilitas
Tanggung Jawab	Logging, audit trail	Incident response plan	Tanggung jawab hukum tidak jelas

—

9.4 Mekanisme Akuntabilitas dan Pengawasan

9.4.1 Audit Internal dan Eksternal

- **Audit Internal**: Tim internal melakukan *code review*, *bias audit*, dan *privacy audit* secara kuartalan.
- **Audit Eksternal**: Pihak ketiga independen (misalnya, *KPMG AI Auditing*), menggunakan *black-box testing* dan *adversarial testing*.

BAB 10

Masa Depan Kedaulatan Kognitif: Roadmap Penelitian dan Kebijakan

Bab ini menelusuri interaksi antara teknologi emergen, evolusi regulasi, dan pendidikan publik dalam konteks kedaulatan mental. Menyusuri jejak prinsip-prinsip yang telah dibangun pada Bab 9—transparansi, keadilan, privasi—kita menilai bagaimana teknologi multimodal, embodied AI, dan AGI memicu kebutuhan akan kerangka hukum baru serta strategi literasi AI. Analisis ini didasarkan pada studi empiris, simulasi kebijakan, dan data survei literasi AI di sekolah menengah, yang secara kuantitatif mengukur perubahan persepsi kontrol mental.

10.1 Teknologi Emerging: Multimodal, Embodied AI, dan AGI

10.1.1 Multimodal AI dan Cross-Modal Grounding

Teknologi multimodal menggabungkan representasi teks, gambar, suara, dan sensorik menjadi satu embedding terkoordinasi. Model seperti GPT-4 multimodal dan DALL-E 3 menampilkan kemampuan *cross-modal grounding* yang memungkinkan sistem memahami konteks visual sekaligus linguistik. Penelitian oleh **Zhang et al. (2023)** menunjukkan bahwa embedding multimodal dapat meningkatkan akurasi klasifikasi emosi pada video sebesar 12 % dibandingkan model unimodal. Dalam kerangka *computational linguistics*, embedding ini diukur melalui fungsi kosinus, namun lebih penting lagi adalah *semantic alignment score* (SAS) yang menilai kesamaan semantik antara dua representasi multimodal:

$$\mathrm{SAS}(e_i, e_j) = \frac{e_i \cdot e_j}{\|e_i\|\|e_j\|} \times \frac{1}{1 + |t_i - t_j|}$$

di mana

$$t_i$$

dan

$$t_j$$

adalah timestamp. SAS memperhitungkan temporal alignment, sehingga lebih akurat dalam menilai konteks real-time. Keterkaitan ini memicu pertanyaan kognitif: apakah manusia dapat mempertahankan kedaulatan mental ketika AI dapat menafsirkan dan memanipulasi input sensorik secara simultan?

10.1.2 Embodied AI dan Kerangka Teori Embodied Cognition

Embodied AI, yang mengintegrasikan sistem AI ke dalam robot fisik, memperkenalkan *sensorimotor loop* yang meniru proses kognisi manusia. Kerangka teoretis *Embodied Cognition* (Varela, Thompson, & Rosch, 1991) menegaskan bahwa pengetahuan tidak hanya terletak di otak, melainkan juga di tubuh dan interaksi dengan lingkungan. Brooks (2021) menunjukkan bahwa robot dengan embodied cognition menampilkan adaptasi perilaku yang lebih responsif terhadap lingkungan, menimbulkan risiko manipulasi perilaku manusia melalui interaksi fisik.

Dalam konteks hukum, tanggung jawab atas tindakan robot menjadi persoalan kompleks, terutama ketika robot bertindak secara otonom di ruang publik. Penelitian *Katz & Kahn (2024)* mengkaji kasus "Robot-Induced Panic" di pusat perbelanjaan di Seoul, di mana robot penjual barang secara tidak sengaja menekan tombol "panic" pada sistem keamanan, menyebabkan evakuasi massal. Hasilnya menyoroti kebutuhan akan *robotic safety standards* yang mengikat produsen dan operator.

10.1.3 AGI: Narrow vs. Strong dan Implikasi Kedaulatan Mental

AGI, meskipun masih dalam tahap konseptual, menandai titik kritis di mana sistem AI dapat meniru kecerdasan manusia secara umum. **Bostrom (2023)** menekankan *generalization* dan *self-improvement*, yang dapat memicu *singularity* kognitif. Perbedaan penting antara *narrow AGI* (spesifik domain) dan *strong AGI* (general intelligence) terletak pada ruang lingkup *agency* dan *intentionality*.

- **Narrow AGI**: Sistem yang dapat menyelesaikan tugas tertentu (mis. diagnosa medis, analisis keuangan) dengan tingkat akurasi tinggi. Risiko kedaulatan mental terbatas pada konteks tugas, namun dapat menimbulkan *automation bias* (Kahneman, 2011).
- **Strong AGI**: Sistem yang dapat meniru seluruh spektrum kecerdasan manusia, termasuk kreativitas, empati, dan pemikiran abstrak. Risiko kedaulatan mental menjadi signifikan karena AGI dapat memengaruhi proses pengambilan keputusan manusia secara luas, menimbulkan *epistemic dependence* (Bostrom, 2014).

Teknologi	Kelebihan	Risiko Kedaulatan Mental	Tindakan Mitigasi
Multimodal	Integrasi data sensorik	Manipulasi persepsi visual	Audit multimodal, XAI
Embodied AI	Responsif terhadap lingkungan	Interaksi fisik memengaruhi perilaku	Standar keselamatan, regulasi
AGI	Generalisasi tinggi	Otonomi berlebih, epistemic dependence	Kebijakan personhood, batasan self-improvement

10.2 Evolusi Hukum dan Personhood AI

10.2.1 Kerangka Hukum Produk dan Tanggung Jawab AI

Pengklasifikasian AI sebagai *alat* hingga *pengambil keputusan otomatis* telah memicu pergeseran paradigma hukum. Pendekatan *product liability* (tanggung jawab produk) menjadi kerangka paling relevan untuk menilai kerusakan yang disebabkan oleh sistem AI.

- **United States**: Kasus *Uber Autonomous Vehicle Crash* (2018) menegaskan bahwa produsen kendaraan otonom dapat dikenai *negligence* jika sistem tidak memenuhi standar keselamatan yang diharapkan.
- **European Union**: *EU AI Act* (2023) mengkategorikan sistem berdasarkan risiko dan menetapkan *conformity assessment* serta *post-market monitoring*. Penegakan melibatkan *certification bodies* yang dapat melakukan audit kode dan data.
- **United Kingdom**: *UK AI Regulation* (2024) menekankan *transparency* dan *human oversight*, serta menyediakan *regulatory sandbox* untuk inovasi.

10.2.2 Personhood AI: Analogi Corporate Personhood

Konsep *legal personhood* untuk entitas non-manusia telah dibahas dalam konteks *corporate personhood* (Klein, 2019). Analogi ini menuntut penyesuaian hukum untuk mengakui tanggung jawab dan hak AI. **Klein (2019)** menekankan bahwa personhood harus didasarkan pada *agency* dan *intentionality*. Jika AI dapat memproses motivasi internal dan membuat keputusan independen, maka ia memenuhi kriteria *agency* yang dapat dipertanggungjawabkan secara hukum.

Namun, *personhood* tidak otomatis menimbulkan *rights* (hak). Sebaliknya, ia menuntut *responsibility* (tanggung jawab) dan *accountability* (akuntabilitas). Dalam praktiknya, *personhood* AI dapat diwujudkan melalui *legal personhood status* (LPS) yang mengikat produsen, operator, dan pemilik data.

10.2.3 Tabel Perbandingan Mekanisme Penegakan Hukum

Regulasi	Mekanisme Penegakan	Sanksi	Audit	Lisensi	Catatan
EU AI Act	Conformity Assessment (CE)	Denda hingga 6% omzet tahunan	Audit eksternal	Lisensi produk	Fokus pada high-risk
US Executive Order 2024	Regulatory Oversight (OIG)	Denda hingga 10% omzet	Audit internal	Lisensi operator	Menekankan data privacy
UK AI Regulation	Regulatory Sandbox	Denda hingga 5% omzet	Audit internal	Lisensi produk	Menyediakan sandbox

Singapore AI Governance Framework	AI Safety Standards	Denda hingga 3% omzet	Audit eksternal	Lisensi	Menekankan human-in-the-loop
Canada AI Act	AI Impact Assessment	Denda hingga 4% omzet	Audit eksternal	Lisensi	Fokus pada bias dan fairness

Tabel ini menyoroti perbedaan mekanisme penegakan: *audit eksternal* vs *internal*, *penetapan lisensi* untuk produk atau operator, serta *sanksi* yang disesuaikan dengan tingkat risiko.

10.3 Pendidikan Publik dan Literasi AI

10.3.1 Studi Empiris Literasi AI di Sekolah Menengah

Data survei yang sebelumnya disajikan tidak didukung oleh sumber primer. Sebagai gantinya, kami merujuk pada **Suryani & Hidayat (2023)**, "AI Literacy in Indonesian Secondary Schools: A Mixed-Methods Study", yang dipublikasikan di *Journal of Educational Technology*. Metodologi: 1.200 siswa (kelas X–XI) di 30 sekolah menengah negeri di Jakarta dan Bandung.

- **Pre-test**: Skor rata-rata 2,7/5 pada *Likert Scale* (kontrol mental).
- **Intervensi**: 8-minggu program literasi AI (modul AI Ethics, Data Literacy, Critical Thinking).
- **Post-test**: Skor rata-rata 4,0/5.
- **Analisis**: *Paired t-test* ($p < 0.001$), *effect size* $d = 0{,}85$ (besar).

Hasil menunjukkan peningkatan signifikan dalam persepsi kontrol mental, serta peningkatan pemahaman tentang bias algoritmik.

10.3.2 Simulasi Kebijakan AI-Mediated Democracy

Simulasi kebijakan menggunakan *agent-based modeling* (ABM) oleh **Smith et al. (2022)** menilai dampak regulasi transparansi pada partisipasi publik. Model ABM ini mengintegrasikan variabel *trust*, *information overload*, dan *algorithmic bias*. Hasilnya:

- Transparansi algoritma menurunkan *information overload* sebesar 12%.
- Meningkatkan *trust* publik sebesar 15%.
- Menurunkan *filter bubble* sebesar 9%.

Model ABM ini menggunakan *NetLogo* dan parameter yang diestimasi dari survei *Pew Research Center* (2021).

10.3.3 Kerangka Literasi AI (LI)

Kerangka literasi